

# Flou dans les images (IMA101) Saïd Ladjal

# Flou dans les images

## Plan

- Rappel de ce qu'est le flou.
- Modèle mathématique.
- Rappels sur les méthodes variationnelles.
- Le problème de la déconvolution aveugle.
- Présentation complète d'une méthode d'estimation du noyau de flou.



# Flou dans les images

## Rappels sur le flou et modèle mathématique

- Intuitivement: La lumière provenant d'un seul point ne va pas sur un unique point du capteur.
- Mathématiquement il s'agit d'une convolution.
  - En effet: Si chaque point lumineux devient une tache lumineuse  $h$  décalée autour de l'image du point alors le résultat total est une convolution.
- Dans la pratique le noyau de flou peut varier suivant la position dans l'image.
- Le flou peut être dû au bougé ou à la mauvaise mise au point.
- Le théorème de Shannon assure que si une image est bien échantillonnée alors la formule de droite reste la même avec pour  $f$  et  $h$  les versions échantillonnées de l'image parfaite et du noyau.

$$g = f \star h + b$$

$f$ : Image parfaite

$h$ : Noyau de flou

$b$ : bruit de mesure

$g$ : image mesurée

# Flou dans les images

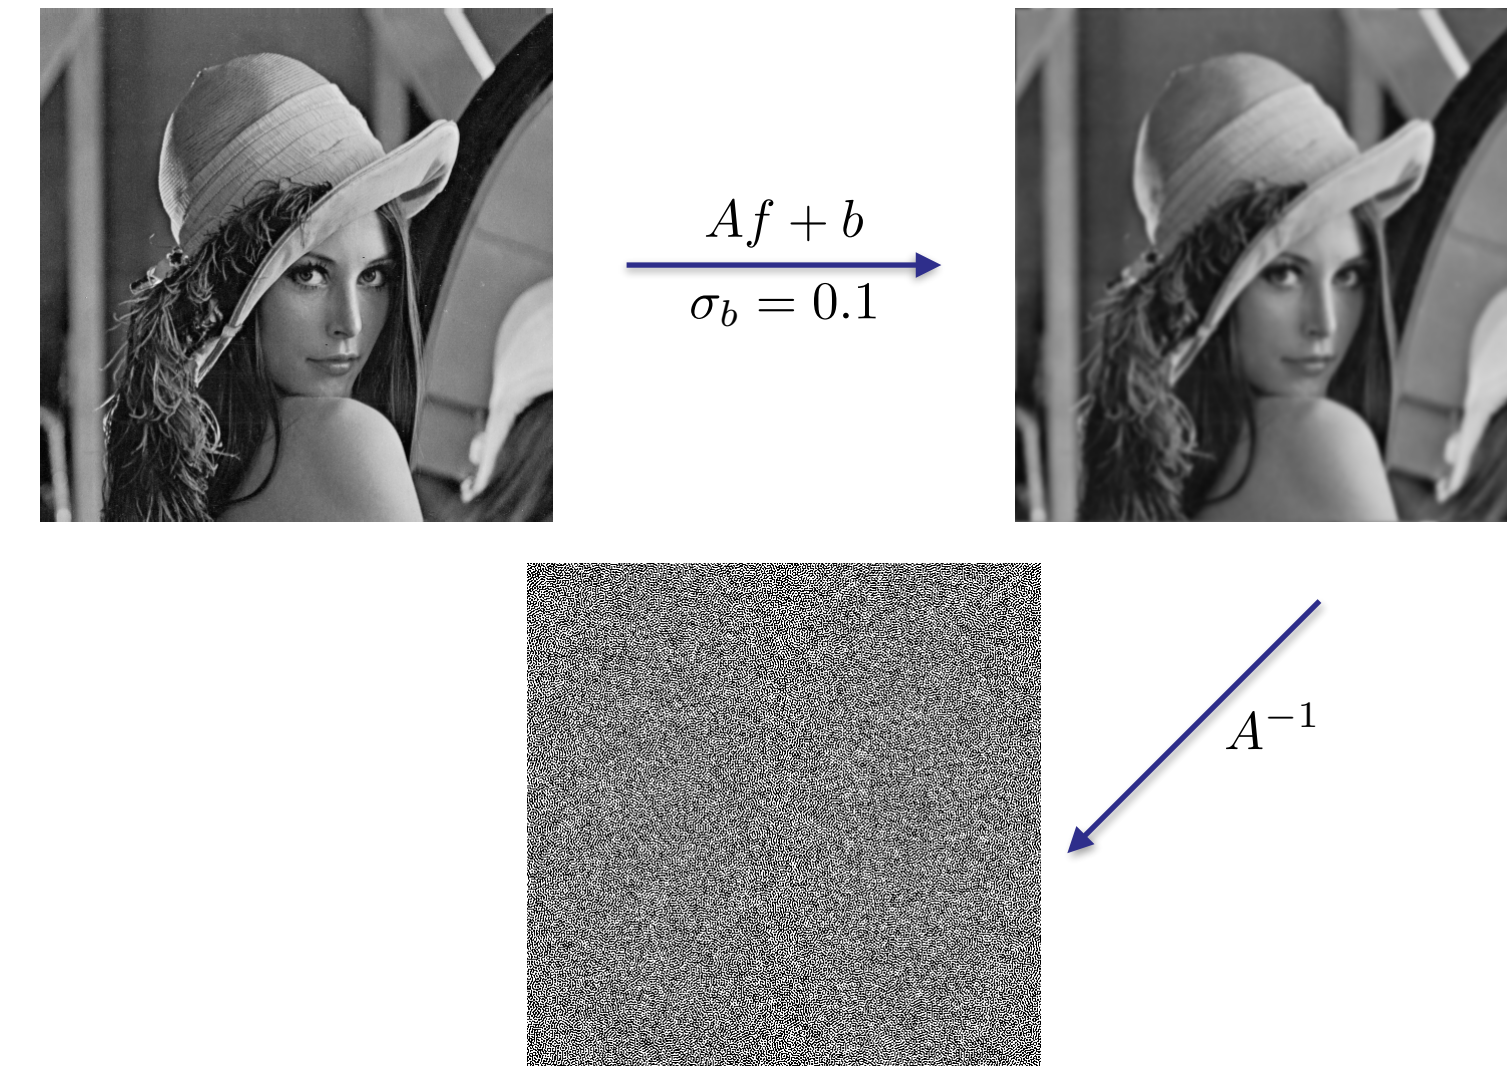
## Rappels sur les méthodes variationnelles

- Pour retrouver l'image d'origine à partir de l'image acquise nous savons que:
  - Il faut connaître le noyau de flou (car il détermine la transformation qui va de l'image parfaite à l'image floue,  $A$ ) (1)
  - Il faut introduire une connaissance supplémentaire sur l'image, souvent du type statistique, sinon la meilleure hypothèse est l'image bruitée  $A^{-1}g$  (c'est le centre de l'ellipse  $\|Ax - g\|^2 = \sigma^2$ ).
  - Les méthodes variationnelles consistent à minimiser une fonction qui a un terme d'**attache aux données** et un terme de **régularité**. (2)

$$g = f \star h + b \iff g = Af + b \quad (1)$$

$$F(\tilde{f}) = \|g - A\tilde{f}\|^2 + \lambda R(\tilde{f}) \quad (2)$$

$R$ : fonction de régularité, grande quand  $\tilde{f}$  est non régulière



# Flou dans les images

## Le problème de la déconvolution aveugle

- Quand on ne connaît pas le noyau de convolution, on dit qu'on a un problème « **aveugle** ».
- La détermination du noyau de convolution est très difficile dans la plupart des cas. Pour plusieurs raisons:
  - Le problème est très mal posé mathématiquement. Une petite erreur sur l'observation devient une grande dans la solution (voir image diapo précédente)
  - Il y a **deux** inconnues: L'**image parfaite** et le **noyau**.
  - On doit donc ajouter des connaissances sur le noyau et sur l'image pour résoudre le problème (Il y a toujours la solution  $f=g$  et  $A=Idem$ . )
  - On peut intuitivement écrire une fonctionnelle comme à droite qui régularise le noyau et l'image et ajoute une attache aux données.
    - Cette fonctionnelle n'est pas convexe et sa minimisation est trop complexe.

$$F(\tilde{f}, \tilde{h}) = R_1(\tilde{f}) + R_2(\tilde{h}) + \|\tilde{f} \star \tilde{h} - g\|^2$$

$\tilde{h}$ : noyau estimé

$\tilde{f}$ : image estimée




# Flou dans les images

## Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method [3]

- Nous allons expliquer la méthode ci-dessus en détail.
- Elle a été choisie pour ses résultats, sa clarté et le fait qu'elle fait intervenir beaucoup de techniques.
  - Vous pouvez la tester sur ipol <<https://ipolcore.ipol.im/demo/clientApp/demo.html?id=211>>
  - Vous en aurez une implémentation complète en TP.
  - Elle se base sur un article original [1].




Image




Module du spectre

noyau



Noyau



Itérations...



Déconvolution











# Flou dans les images


## Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method

- **La dernière étape:** Il s'agit simplement de la **déconvolution** par la fonctionnelle de droite.
- Attention les auteurs ont utilisé  $\lambda$  comme paramètre devant l'attache aux données.
- Ils utilisent une méthode d'optimisation Split-Bregman ([2])

$$F(\tilde{f}) = TV(\tilde{f}) + \lambda \|g - h \star \tilde{f}\|^2$$




Image




Module du spectre

noyau



Noyau



Itérations...



Déconvolution




# Flou dans les images

## Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method

- **La première étape:** Il s'agit de la plus innovante de la méthode.
  - Le but est de trouver le module de transformée de Fourier du noyau à partir de l'image.
  - Les auteurs se basent sur les fait suivants:
- L'autocorrélation du gradient dans la direction  $\theta$  contient presque l'autocorrélation du noyau dans la direction  $\theta$ :
    - Pour arriver à ce résultat on suppose un modèle d'image dont le spectre est de la forme:

$$|\hat{u}(\xi \mathbf{n}_\theta)|^2 \approx (\epsilon + c_\theta^{-1} \cdot |\xi|^2)^{-1}.$$






# Flou dans les images

## Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method

- L'autocorrélation du gradient dans la direction  $\theta$  contient presque l'autocorrélation du noyau dans la direction  $\theta$ :
  - Pour arriver à ce résultat on suppose un modèle d'image dont le spectre est de la forme:
- $c_\theta$  est le seul paramètre de l'image qui reste à éliminer pour accéder à la puissance du noyau de convolution.

$$|\hat{u}(\xi \mathbf{n}_\theta)|^2 \approx (\epsilon + c_\theta^{-1} \cdot |\xi|^2)^{-1}.$$




# Flou dans les images

## Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method

- **La seconde étape:** Il s'agit de trouver un noyau à partir du module de sa transformée de Fourier.
- Elle se nomme SinglePhaseRetrieval
- En fait cette brique est utilisée dans des boucles car elle ne donne pas forcément le meilleur résultat en un coup (elle utilise un algorithme non déterministe).



Image



Module du spectre

noyau

Noyau

---

### Algorithm 5: SinglePhaseRetrieval

---


input : discrete kernel spectrum magnitude  $|H|$  of size  $rM_h \times rM_h$ , kernel size  $s$   
output: kernel  $h$  of size  $s \times s$   
 $\alpha = 0.95$   
 $\beta_0 = 0.75$   
initialize a Hermitian symmetric random phase  $\phi(G)_{m,n}$   
 $g = \mathcal{F}^{-1}(|H| \cdot e^{i \cdot \phi(\hat{g})})$  *Associate the magnitude and the random phase*  
for  $m$  from 0 to  $N_{inner} - 1$  do  
 $\beta = \beta_0 + (1 - \beta_0)(1 - \exp(-(m/7)^3))$   
 $g' = \mathcal{F}^{-1}((\alpha \cdot |H| + (1 - \alpha) \cdot |G|) \cdot e^{i \cdot \phi(G)})$  *Enforce the spectrum magnitude constraint*  
 $\Omega = \{(k, l) : 2 \cdot g'_{k,l} < g_{k,l}\} \cup \{(k, l) : (k, l) \notin [0, s]^2\}$  *Invalid values of the kernel*  
 $g_{k,l} = \begin{cases} \beta \cdot g_{k,l} + (1 - 2\beta) \cdot g'_{k,l} & \text{if } (k, l) \in \Omega \\ g'_{k,l} & \text{otherwise} \end{cases}$  *Enforce the support and positivity constraints*  
 $h_{k,l} = \max(g'_{k,l}, 0), \quad \forall (k, l) \in [0, s]^2$   
 $k = k / \sum_{k,l} k_{k,l}$  *Normalize the kernel*  
 $h = \text{thresholding}(h, 1/255)$  *Simple kernel denoising*  
 $k = k / \sum_{k,l} k_{k,l}$  *Re-normalize the kernel*

---

# Flou dans les images

## Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method

- **Les itérations:** Une seule SinglePhase Retrieval ne suffit pas.
  - Une fois fixé un spectre de puissance on fait plusieurs SinglePhaseRetrieval pour et ne garder que le meilleur noyau (parmi une trentaine).
  - Une fois un noyau choisi, on l'utilise seulement pour déterminer la partie utile (le support) des autocorrélations
  - On en déduit un nouveau spectre de puissance.



Noyau

Itérations...

---

### Algorithm 6: PhaseRetrieval

---

input : kernel power spectrum  $|H|^2$ , kernel size  $s$ , blurred image  $v$

output: kernel  $h$  of size  $s \times s$

$P$  = extract a high variance  $150 \times 150$  patch of  $v$  (10 random window samples)

for  $j$  from 1 to  $N_{tries}$  do

$h^{(j)} = \text{SinglePhaseRetrieval}(|H|, s)$

*Algorithm 5*

$d^{(j)} = \text{deconv}(P, h^{(j)})$

$c^{(j)} = \frac{\sum_x |\nabla d_x^{(j)}|}{\sqrt{\sum_x |\nabla d_x^{(j)}|^2}}$

$\nabla d$  computed by finite differences

$h^{(j+N_{tries})} = \text{reflect}(h^{(j)})$

$d^{(j+N_{tries})} = \text{deconv}(P, h^{(j+N_{tries})})$

*Evaluate the mirror kernel*

$c^{(j+N_{tries})} = \frac{\sum_x |\nabla d_x^{(j+N_{tries})}|}{\sqrt{\sum_x |\nabla d_x^{(j+N_{tries})}|^2}}$

return the kernel  $h^{(j)}$  with lowest cost  $c^{(j)}$

---



# Flou dans les images

## Instructions pour le TP

- le but du TP est de tester la méthode ainsi que ses composantes.
  - C'est une méthode très complexe avec beaucoup de composantes.
  - La première à tester est la déconvolution par variation totale.
  - Ensuite le SinglePhaseRetrieval
  - Et enfin la méthode entières.
  - Je vous donne quelques exemples de questions dans la colonne de droite.
  - Le but est de comprendre le plus possible, et surtout de comprendre que tout est dans les détails.
- Quelle méthode TVdeconv utilise-t-elle pour résoudre les problèmes de bords?
  - SinglePhaseRetrieval est stable au bruit, mais jusqu'à quel point?
  - Démontrer que l'autocorrélation de la projection est la même chose que la projection de l'autocorrélation.
  - La méthode original propose de calculer pour chaque  $\theta$  la projection du gradient  $\theta$  puis autocorrélation.
    - Dans le script fourni qu'est-ce qui est fait? Pour quelle tailles d'images cela devient-il intéressant.
    - Pourquoi y-a-t-il des /255 dans le code (les auteurs donnent des lambda pour des images entre 0 et 1)? Justifier en vous référent aux fonctionnelles à minimiser.
    - En visualisant des images Cb et Cr, pourquoi ne sont-elles pas défloutées à votre avis?

## Références:

- [1] A. Goldstein and R. Fattal, Blur-kernel estimation from spectral irregularities, in European Conference on Computer Vision (ECCV), Springer, 2012, pp. 622–635. [https://doi.org/10.1007/978-3-642-33715-4\\_45](https://doi.org/10.1007/978-3-642-33715-4_45).
- [2] P. Getreuer, Total Variation Deconvolution using Split Bregman, Image Processing On Line, 2 (2012), pp. 158–174. <https://doi.org/10.5201/ipol.2012.g-tvdc>.
- [3] Jérémy Anger, Gabriele Facciolo, and Mauricio Delbracio, Estimating an Image's Blur Kernel Using Natural Image Statistics, and Deblurring it: An Analysis of the Goldstein-Fattal Method, [Image Processing On Line](#), [8](#) (2018), pp. 282–304. <https://doi.org/10.5201/ipol.2018.211>