

I. Introduction

Supervised binary classification:

Gen approach:

How to model $p(x_i, y_i)$?

Naive Bayes, Generative / Hidden Markov Model

Discriminative approach

Which feature allow to distinguish?

→ draw a boundary

Decision Trees, SVMs

II The formal neuron and Perceptron

Perceptron: $\hat{y}_i = \text{sign}(\omega^T x_i + b)$, $\theta = \{\omega, b\}$ parameters of the model

Learning procedure

Init: $\omega_t = 0$

Boucle: $\forall i \in [1, n]$

• $\hat{y}_i = \text{sign}(\omega^T x_i)$

• Si $y_i \neq \hat{y}_i$: $\omega_{t+1} = \omega_t + \text{sign}(y_i) x$

Algo O si les classes sont
linéairement séparables
→ $\frac{R^2}{\gamma^2}$ it

Limites: → Quality of the boundary
→ Case of non-linear separability

Loss function: • zero-one: $1 - y \cdot \text{sign}(f(x, \omega))$

• hinge: $\max(0, 1 - y \cdot f(x, \omega))$

• MSE: $(y - f(x, \omega))^2$

Sigmoid: on remplace sign par $\sigma(x) = \frac{e^x}{1+e^x}$ → différentiable

⇒ $\hat{y}_i = \sigma(\omega^T x_i)$

→ c'est maintenant une proba

Probabilistic loss function: NLE estimation

$$\ell_{NLE}(\theta) = -\log \mathcal{L}(\theta) \quad \text{avec} \quad \mathcal{L}(\theta) = \prod f(x_i, \omega)^{y_i} (1 - f(x_i, \omega))^{1-y_i}$$

Gradient: $\frac{\partial \ell_{NLE}}{\partial \omega^j} = -\sum [y_i - f(x_i, \omega)] x_i^j$

Gradient-based learning procedure:


• While $\|\ell_{NLE}(\omega_{t+1}) - \ell_{NLE}(\omega_t)\| > \delta$ et $t > miter$:

• Pour $j \in [1, d]$:

$$\omega_{t+1}^j = \omega_t^j + \varepsilon \sum_i [y_i - f(x_i, \omega)] x_i^j$$

III - Multi-Layer Perceptron

Neurons are grouped into layers:



$$h^{(1)} = \phi^{(1)}(\omega^{(1)T} x + b^{(1)})$$

ϕ fonction d'activation possiblement non-linéaire

↳ chaque layer est une fonction du layer précédent

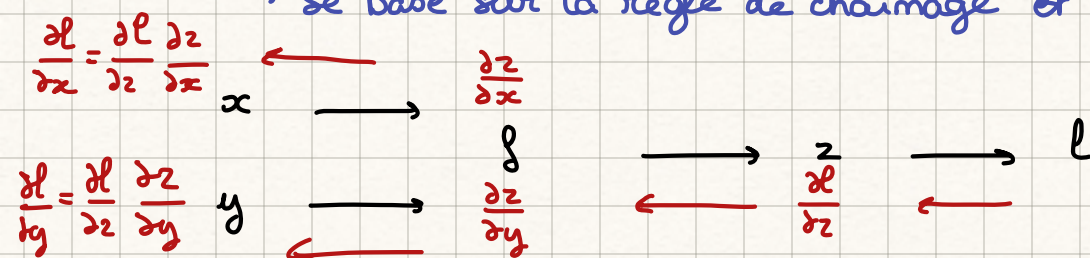
Activation: $\sigma(x) = \frac{1}{1+e^{-x}}$, $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

• Softmax: $\hat{o}_i = \left[\frac{e^{\lambda^{(1),k}}}{\sum e^{\lambda^{(1),k}}}, \dots \right]$

↳ généralisation de la sigmoid pour k sorties

Optimisation: Backpropagation

→ se base sur la règle de chaînage et fonctionne récursivement



IV - Model and Hyperparameter selection

→ Split data into train / test et choisis les hyperparamètres
↓ MEUX

→ Split into train / validation / test
to tune h.p. to verify perf

Choice of learning rate ϵ :

- Si perf \uparrow sur validation data : $\epsilon = \epsilon * \alpha$ $\alpha \in [0, 1]$
- ou . Step decay : $\forall \alpha$ tous les N epochs
- ou . exponential decay : $\epsilon^{(t)} = \epsilon^{(0)} e^{-\alpha t}$

Regularisation : To avoid overfitting

$$\ell_{\text{reg}}(\omega) = \ell_{\text{MLE}}(\omega) + \lambda \omega^T \omega$$

$$\Rightarrow \omega^{t+1} = (1 - 2\lambda) \omega^t - \epsilon \nabla_{\omega} \ell_{\text{MLE}}$$

Initialisation : dépend beaucoup des activateurs & des méthodes d'optim

mais souvent $\omega^{(i)} \sim \mathcal{N}(0, \frac{1}{d_i})$

Advantages : → very flexible in term of input / output
→ backpropagation allows efficient updates
→ SGD allows efficient training m pr grosse data

Mais : → Gradient descent pas facile à exécuter
→ bcp d'hyperparamètres
→ risque overfitting (not enough data)
→ optimisation hard → underfitting

Solution : underfitting : more data
better optim

overfitting : find better way to regularise
→ unsupervised : init hidden layers with unsupervised learning

→ dropout : randomly remove parts of hidden layers

Better optimization: Adaptive gradient

Better activation: ReLU ; $\text{relu}(x) = \max(0, x)$
→ avoid saturated & vanishing grad.

Better init: Unsupervised pre-training

↳ fine tuning = ajout d'un output et entraînement supervisé après cette init

Better reg: Dropout