

Mesures de risque

Christian GOURIEROUX et Jean-Michel ZAKOIAN

Contents

1	Introduction	1
1.1	Risque financier	1
1.2	Régulation	2
2	Réserves et mesures de risque	4
2.1	Facteurs de risque et distributions de perte	4
2.2	VaR	5
2.2.1	Définition et interprétations	5
2.2.2	VaR et moments conditionnels	7
2.2.3	VaR et queues de distributions	9
2.3	Agrégation de risques	10
2.3.1	Modèle à facteur iid	10
2.3.2	Modèle à facteur autocorrélé	13
2.4	Autres mesures de risque	14
2.4.1	Volatilité et moments	14
2.4.2	Expected shortfall	14
2.4.3	Mesures de distorsion	17
2.5	Sensibilité par rapport à la composition de portefeuille	20
2.6	Mesures de risque cohérentes	22
3	Estimation	27
3.1	Propriétés de la fonction de répartition empirique	27
3.2	Fonction quantile empirique	29
3.2.1	Calcul des quantiles empiriques	29
3.2.2	Propriétés asymptotiques	30
3.3	Méthodes d'estimation des mesures de risque	34
3.3.1	Estimation non paramétrique	34
3.3.2	Modèles dynamiques des moments conditionnels	36
3.3.3	Régression quantile	39
3.3.4	Modèles dynamiques de la VaR	42

<i>CONTENTS</i>	iii
A Examens	46
B Fonction quantile	61
B.1 Fonction quantile	61
B.2 Agrégation de fonctions quantiles	62
B.3 Dérivées du quantile d'une combinaison linéaire	63
B.4 Variables non absolument continues	63
B.5 Théorème central limite pour tableaux triangulaires	65
C Références	66

Chapter 1

Introduction

En finance, les investisseurs, banques et autres intervenants des marchés financiers voient leur capital exposé au *risque*. Il est donc utile de *quantifier* le risque de telle ou telle position afin de décider s'il est acceptable ou non.

Par ailleurs, de nouvelles régulations sont actuellement mises en place. Pour les établissements financiers (Bâle II), pour les compagnies d'assurance (Solvency II) suite à des sous-évaluations des réserves.

Pour ces raisons, diverses classes de mesures de risque ont été introduites. Nous commençons par préciser les diverses notions de risque rencontrées en finance et assurance avant de donner un bref historique des nouvelles régulations. On se référera au chapitre 1 de Gouriéroux et Tiomo (2007).

1.1 Risque financier

Les principaux risques rencontrés en finance sont les suivants, sans que la frontière entre eux soit toujours claire.

- Le risque de marché: risque de changement de la valeur d'une position financière due aux changements des composantes dont elle dépend (actions, obligations, taux de change, prix de matières premières...)
- Le risque de crédit: risque de ne pas recevoir les paiements prévus à cause du "défaut" de l'emprunteur.
- Les risques opérationnels: risque de pertes liées à des défaillances de processus internes (personnes ou systèmes) ou externes. Exemple: incendie, fraude, risque judiciaire.

- Le risque de liquidité: risque lié au fait qu'un investissement peut ne pas être effectué suffisamment rapidement pour éviter une perte.
- Le risque de modèle: risque lié à l'utilisation d'un modèle mal spécifié (ex: Black-Scholes alors que les rendements ne sont pas gaussiens). D'une certaine façon ce risque est toujours présent, mais à des degrés différents.

La *mesure du risque* est une question statistique: à partir de données historiques et d'un modèle probabiliste, il s'agit d'évaluer les risques encourus pour une position. La *gestion du risque* est le métier d'une banque ou compagnie d'assurance.

1.2 Régulation

La régulation des dernières années a été conduite par le Comité de Bâle, créé en 1974 par le G-10. Le comité n'a pas d'autorité supranationale et ses conclusions n'ont pas de force légale. Il formule des recommandations que les institutions nationales sont libres de suivre en les adaptant.

Les étapes de la mise en place de procédures de régulation ont été les suivantes.

- Bâle I: les premières directives, relatives principalement au risque de crédit, datent de 1988. La mesure du risque proposée (ratio Cooke) était trop fruste et insuffisamment différenciée.
- Naissance de la VaR: 1993, dans différents rapports. En 1996, un amendement à Bâle I préconise un *modèle standard* pour le risque de marché mais autorise les banques les plus grosses à opter pour un modèle interne, fondé sur la VaR. Le délicat problème du risque de crédit n'est pas résolu et les banques se plaignent de ne pas avoir assez d'incitation pour diversifier ce risque.
- Bâle II: le processus consultatif pour un deuxième accord est initié en 2001. L'approbation des dispositions définitives de Bâle II, par les gouverneurs de la banque centrale, date de juin 2004. En 2005: début du délai transitoire d'une année. Fin 2006: introduction de Bâle II dans les différents pays.

Une différence importante par rapport à Bâle I est l'introduction dans Bâle II du concept de *trois piliers*:

- Pilier I: une exigence minimale de fonds propres. Ces fonds propres s'appliquent au risque de marché (déjà dans Bâle I), au risque de crédit (substantiellement révisé par rapport à Bâle I) et, pour la première fois, au risque opérationnel.
- Pilier II: mise en place et validation des procédures internes de suivi et contrôle des risques.
- Pilier III: discipline de marché et transparence incluant les questions de diffusion et d'échange d'informations.

Deux types d'approches ont été prévues dans un premier temps:

- L'approche *avancée* repose sur des méthodes relativement sophistiquées de calcul des risques (utilisation de lois conditionnelles)
- L'approche *standard* repose sur des méthodes plus simples mais requiert des réserves plus importantes.

Les établissements financiers ont la possibilité de développer leur propre modèle de gestion du risque. la commission bancaire valide le modèle et impose des niveaux de fonds propres fonction de la qualité du modèle proposé.

Chapter 2

Réserves et mesures de risque

Plusieurs aspects sont importants dans la fixation des réserves. Il faut:

- définir précisément la ligne du "bilan" à laquelle on s'intéresse (incluant l'horizon d'analyse). Ex: pour un portefeuille d'actions faut-il inclure les dividendes? le risque de liquidité? de crédit?
- déterminer l'incertitude sur cette ligne à partir d'un modèle probabiliste. Le problème est rapidement difficile à cause du grand nombre d'actifs, du manque de données, de faits stylisés compliqués.
- déterminer à partir de ce modèle un résumé scalaire pour mesurer le risque, puis fixer le montant de réserves en fonction de ce résumé. Il faut également expliquer comment ces réserves apparaîtront dans le bilan.

Avant de définir la VaR, notion centrale dans la mise en place de régulations dans les institutions financières, nous introduisons la notion de distribution de perte. Dans tout ce chapitre, les variables seront considérées comme continues, ce qui permet d'éviter des difficultés dans la définition des quantiles (des extensions aux variables quelconques sont présentées en annexe).

2.1 Facteurs de risque et distributions de perte

Soit un portefeuille dont la valeur à l'instant t est une v.a. notée V_t . A horizon h , la *perte* est notée

$$L_{t,t+h} = -(V_{t+h} - V_t).$$

La loi de $L_{t,t+h}$ est appelée *distribution de perte* (conditionnelle ou non). Cette distribution permet de calculer des réserves, qui seront insuffisantes pour couvrir tous les risques. En général V_t est modélisé comme une fonction de d *facteurs de risque* observables.

Considérons par exemple un portefeuille constitué de d actions. Le prix de l'action i à la date t est noté $S_{i,t}$ et on note $r_{i,t,t+h} = \log S_{i,t+h} - \log S_{i,t}$ le rendement en logarithme. En notant a_i le nombre d'actions i dans le portefeuille on a

$$V_t = \sum_{i=1}^d a_i S_{i,t}$$

et donc, en supposant fixe la composition du portefeuille en les dates t et $t+h$,

$$L_{t,t+h} = - \sum_{i=1}^d a_i S_{i,t} (e^{r_{i,t,t+h}} - 1).$$

La distribution de V_{t+h} conditionnelle au passé jusqu'à la date t est appelée loi de perte et profit ("Profit and Loss (P&L) distribution").

La fixation du niveau de réserve dépend

- du portefeuille
- de la date t (information) et de l'horizon h
- du niveau de risque jugé admissible (paramétré par le réel $\alpha \in]0, 1[$).

On notera $R_{t,h}(\alpha)$ ce niveau de réserves. Avec ces réserves, non rémunérées, la ligne du bilan à $t+h$ devient $V_{t+h} + R_{t,h}(\alpha)$. On peut fixer les réserves les plus petites vérifiant

$$P_t[V_{t+h} + R_{t,h}(\alpha) < 0] < \alpha, \quad (2.1)$$

soit

$$P_t[V_{t+h} < -R_{t,h}(\alpha)] < \alpha.$$

En général, $-R_{t,h}(\alpha)$ est donc le quantile de niveau α de la loi conditionnelle de V_{t+h} , i.e. la loi de perte et profit.

2.2 VaR

2.2.1 Définition et interprétations

Le capital pour couvrir le risque, ou *Value at Risk* comporte aussi la valeur courante du portefeuille:

$$\text{VaR}_{t,h}(\alpha) = V_t + R_{t,h}(\alpha).$$

La VaR s'interprète donc comme le capital exposé ou "valeur en risque" en cas de ruine. Une autre interprétation est la suivante. On a

$$P_t[V_{t+h} - V_t < -\text{VaR}_{t,h}(\alpha)] < \alpha$$

ou encore

$$P_t[\text{VaR}_{t,h}(\alpha) < L_{t,t+h}] < \alpha, \quad \text{i.e.} \quad P_t[L_{t,t+h} \leq \text{VaR}_{t,h}(\alpha)] \geq 1 - \alpha. \quad (2.2)$$

Nous adopterons la définition suivante.

Définition 2.1 On appelle VaR au niveau α , le quantile d'ordre $1 - \alpha$ de la distribution conditionnelle de perte:

$$\text{VaR}_{t,h}(\alpha) := \inf\{x \in \mathbb{R} \mid P_t[L_{t,t+h} \leq x] \geq 1 - \alpha\},$$

lorsque ce quantile est positif. Par convention $\text{VaR}_{t,h}(\alpha) = 0$ sinon.

En particulier $\text{VaR}_{t,h}(\alpha)$ augmente lorsque α décroît.

Remarque 2.1 Pour la gestion du risque de marché, on a typiquement $h = 1$ jour ou 10 jours. Pour le régulateur (risque de crédit ou opérationnel) $h = 1$ an, $\alpha = 5\%$ ou 3% . Dans l'approche dite "standard", la loi conditionnelle est remplacée par la loi marginale.

Remarque 2.2 Un avantage de la VaR, par rapport au niveau de réserve, est qu'elle est un quantile de la loi d'une variation de prix (en générale supposée stationnaire).

Remarque 2.3 On peut également interpréter la VaR comme un capital optimal pour une certaine fonction de coût. Supposons que l'on cherche le capital z_t , déterminé à la date t , minimisant l'espérance conditionnelle d'un coût

$$c_{t+h} = (1 - \alpha)(L_{t,t+h} - z_t)^+ + \alpha(z_t - L_{t,t+h})^+.$$

Ainsi, pour α petit, un coût faible est associé à une réserve sur-évaluée mais un coût important est associé à des pertes dépassant la réserve. Une valeur de z_t qui minimise l'espérance conditionnelle de ce coût est précisément $\text{VaR}_{t,h}(\alpha)$.¹ La VaR réalise donc un compromis optimal entre une perte excessive et un capital inutilisé excessif.

¹Pour une v.a. X , de loi F continue et telle que $E|X| < \infty$, soit

$$f(z) = (1 - \alpha)E(X - z)^+ + \alpha E(z - X)^+ = (1 - \alpha) \int_z^\infty (x - z)dF(x) + \alpha \int_{-\infty}^z (z - x)dF(x)$$

2.2.2 VaR et moments conditionnels

Introduisons les deux premiers moments conditionnels à l'information disponible à la date t de $L_{t,t+h}$:

$$m_{t,t+h} = E_t(L_{t,t+h}), \quad \sigma_{t,t+h} = V_t(L_{t,t+h}).$$

Supposons que

$$L_{t,t+h} = m_{t,t+h} + \sigma_{t,t+h} L_h^* \quad (2.3)$$

où L_h^* est une variable aléatoire de fonction de répartition F_h . On a alors d'après (2.2)

$$1 - \alpha = P_t[\text{VaR}_{t,h}(\alpha) \geq m_{t,t+h} + \sigma_{t,t+h} L_h^*] = F_h \left(\frac{\text{VaR}_{t,h}(\alpha) - m_{t,t+h}}{\sigma_{t,t+h}} \right).$$

Par suite

$$\text{VaR}_{t,h}(\alpha) = m_{t,t+h} + \sigma_{t,t+h} F_h^{\leftarrow}(1 - \alpha). \quad (2.4)$$

La VaR se décompose donc en une "perte attendue" $m_{t,t+h}$, la moyenne conditionnelle des pertes, et une "perte inattendue" $\sigma_{t,t+h} F_h^{\leftarrow}(1 - \alpha)$, appelée aussi *capital économique*.

La simplicité apparente de la formule (2.4) cache les difficultés (i) de calcul des moments conditionnels pour un modèle donné et (ii) de détermination de la loi F_h , supposée indépendante de t , des rendements normalisés à horizon h .

Soit un portefeuille de prix $p_t = a'P_t$, où $a, P_t \in \mathbb{R}^d$. On a, en introduisant les variations de prix $\Delta P_t = P_t - P_{t-1}$,

$$L_{t,t+h} = -(p_{t+h} - p_t) = -a'(P_{t+h} - P_t) = -a' \sum_{i=1}^h \Delta P_{t+i}.$$

Considérons sur plusieurs exemples la *structure par terme* de la VaR, c'est à dire son évolution en fonction de l'horizon.

la fonction à minimiser. Cette fonction est convexe (donc continue) et $\lim_{|z| \rightarrow \infty} f(z) = +\infty$. Le minimum est atteint en tout point z^* tel que

$$0 = f'(z^*) = -(1 - \alpha) \int_{z^*}^{\infty} dF(x) + \alpha \int_{-\infty}^{z^*} dF(x) = \alpha - 1 + F(z^*).$$

Le quantile d'ordre $1 - \alpha$ de F est donc solution. Plus précisément, l'ensemble des solutions est le compact $[q_{1-\alpha}, q^{1-\alpha}]$ des points situés entre les quantiles inférieur et supérieur de X .

Exemple 2.1 VARIATIONS DE PRIX iid GAUSSIENNES. Si les ΔP_{t+i} sont iid de loi $\mathcal{N}(m, \Sigma)$, la loi de $L_{t,t+h}$ est la loi $\mathcal{N}(-a'mh, a'\Sigma ah)$. Par suite, d'après (2.4),

$$\text{VaR}_{t,h}(\alpha) = -a'mh + \sqrt{a'\Sigma a} \sqrt{h} \Phi^{-1}(1 - \alpha). \quad (2.5)$$

En particulier, si $m = 0$, on a $\text{VaR}_{t,h}(\alpha) = \sqrt{h} \text{VaR}_{t,1}(\alpha)$. Cette règle consistant à multiplier la VaR à horizon 1 par $\sqrt{h}$ pour obtenir la VaR à horizon h est souvent utilisée à tort lorsque les variations de prix ne sont pas iid, centrées et gaussiennes. Par exemple si la suite $(a'\Delta P_t)$ est iid de loi double-exponentielle de paramètre λ , c'est à dire de densité $f(x) = 0.5\lambda \exp\{-\lambda|x|\}$, on a $\text{VaR}_{t,1}(\alpha) = -\log(2\alpha)/\lambda$. On vérifie facilement que la loi de $L_{t,t+2}$ a pour densité $g(x) = 0.25\lambda \exp\{-\lambda|x|\}(1 + \lambda|x|)$. La VaR à horizon 2 est donc la solution u de l'équation $(2 + \lambda u) \exp\{-\lambda u\} = 4\alpha$. Par exemple, pour $\lambda = 0.1$ on obtient $\text{VaR}_{t,2}(0.01) = 51.92$ tandis que $\sqrt{2} \text{VaR}_{t,1}(0.01) = 55.32$. La VaR est donc sur-évaluée en appliquant la règle incorrecte mais, pour d'autres valeurs de α on peut avoir sous-évaluation: $\text{VaR}_{t,2}(0.05) = 32.72$ tandis que $\sqrt{2} \text{VaR}_{t,1}(0.05) = 32.56$.

Exemple 2.2 VARIATIONS DE PRIX AR(1). Supposons maintenant que

$$\Delta P_t - m = A(\Delta P_{t-1} - m) + U_t, \quad (U_t) \text{ iid } \mathcal{N}(0, \Sigma)$$

où A est une matrice dont les valeurs propres sont de module strictement inférieur à 1. Le processus (ΔP_t) est alors stationnaire d'espérance m . On a

$$\Delta P_{t+i} - m = A^i(\Delta P_t - m) + U_{t+i} + AU_{t+i-1} + \dots + A^{i-1}U_{t+1}.$$

Donc, en posant $A_i = (I - A^i)(I - A)^{-1}$,

$$\begin{aligned} L_{t,t+h} &= -a' \sum_{i=1}^h \left(m + A^i(\Delta P_t - m) + \sum_{j=1}^i A^{i-j} U_{t+j} \right) \\ &= -a'mh - a'AA_h(\Delta P_t - m) - a' \sum_{j=1}^h \left(\sum_{i=j}^h A^{i-j} \right) U_{t+j} \\ &= -a'mh - a'AA_h(\Delta P_t - m) - a' \sum_{j=1}^h A_{h-j+1} U_{t+j}. \end{aligned}$$

La loi conditionnelle de $L_{t,t+h}$ est donc la loi $\mathcal{N}(a'\mu_{t,h}, a'\Sigma_h a)$ où

$$\mu_{t,h} = -mh - AA_h(\Delta P_t - m), \quad \Sigma_h = \sum_{j=1}^h A_{h-j+1} \Sigma A_{h-j+1}'.$$

Par suite

$$\text{VaR}_{t,h}(\alpha) = a' \mu_{t,h} + \sqrt{a' \Sigma_h a} \Phi^{-1}(1 - \alpha).$$

Dans la cas où $A = 0$, cette formule se réduit à (2.5). En dehors de ce cas, le terme en facteur de $\Phi^{-1}(1 - \alpha)$ n'est pas proportionnel à $\sqrt{h}$.

Exemple 2.3 VARIATIONS DE PRIX ARCH(1). Supposons $d = 1$, $a = 1$ pour simplifier et

$$\Delta P_t = \sqrt{\omega + \alpha_1 \Delta P_{t-1}^2} U_t, \quad \omega > 0, \alpha_1 \geq 0, \quad (U_t) \text{ iid } \mathcal{N}(0, 1).$$

La loi conditionnelle de $L_{t,t+1}$ est donc la loi $\mathcal{N}(0, \omega + \alpha_1 \Delta P_t^2)$ donc

$$\text{VaR}_{t,1}(\alpha) = \sqrt{\omega + \alpha_1 \Delta P_t^2} \Phi^{-1}(1 - \alpha).$$

Le calcul de la VaR à un horizon plus grand que 1 est ici problématique. En effet, la loi conditionnelle de $L_{t,t+h}$ n'est pas normale. Par exemple à horizon 2, on a

$$\Delta P_{t+2} = \sqrt{\omega + \alpha_1 \Delta P_{t+1}^2} U_{t+2} = \sqrt{\omega + \alpha_1 (\omega + \alpha_1 \Delta P_t^2) U_{t+1}^2} U_{t+2}.$$

La loi conditionnelle de ΔP_{t+2} n'est pas gaussienne si $\alpha_1 > 0$, car elle a un coefficient de Kurtosis égal à

$$\frac{E_t \Delta P_{t+2}^4}{(E_t \Delta P_{t+2}^2)^2} = 3 \left(1 + \frac{2\theta_t^2}{(\omega + \theta_t)^2} \right) > 3, \quad \theta_t = \alpha_1 (\omega + \alpha_1 \Delta P_t^2).$$

2.2.3 VaR et queues de distributions

D'après (2.2), la VaR est définie comme un quantile supérieur de la distribution de perte conditionnelle. La figure 2.1 compare les VaR de 3 lois, ayant la même variance mais des queues de distribution plus ou moins épaisses. La loi de Student $\mathcal{S}$ a la queue la plus épaisse, proportionnelle à $1/x^4$, la loi normale $\mathcal{N}$ a la queue la moins épaisse, et la loi double-exponentielle $\mathcal{E}$ possède une queue de taille intermédiaire, proportionnelle à $e^{-\sqrt{2}|x|}$. Pour un niveau α très petit, les VaR seront rangées en fonction de l'épaisseur des queues: $\text{VaR}(\mathcal{N}) < \text{VaR}(\mathcal{E}) < \text{VaR}(\mathcal{S})$. Le graphe de droite de la figure 2.1 montre que ce n'est pas le cas pour les niveaux usuels $\alpha = 1\%$ et $\alpha = 5\%$.




Figure 2.1: La VaR est le quantile d'ordre $1 - \alpha$ de la distribution conditionnelle des pertes (graphe de gauche). Le graphe de droite représente la VaR en fonction de $\alpha \in [1\%, 5\%]$ pour une distribution des pertes de loi normale $\mathcal{N}$ (trait plein), de loi de Student à 3 degrés de libertés $\mathcal{S}$ (tirés) et de loi double exponentielle $\mathcal{E}$ (trait pointillé fin). Les 3 lois sont normalisées pour avoir une variance de 1. Pour $\alpha = 1\%$ on a $\text{VaR}(\mathcal{N}) < \text{VaR}(\mathcal{S}) < \text{VaR}(\mathcal{E})$, pour $\alpha = 5\%$ on a $\text{VaR}(\mathcal{S}) < \text{VaR}(\mathcal{E}) < \text{VaR}(\mathcal{N})$.

2.3 Agrégation de risques: diversification et contagion²

Il est fréquent de devoir tenir compte de plusieurs sources de risques. Ces risques peuvent procurer de la *diversification* mais également de la *contagion*. Le calcul de la VaR dans un tel contexte pose de nombreux problèmes. Nous considérons plusieurs modèles emboîtés, à facteur inobservable. Pour simplifier, nous nous considérerons dans cette partie les risques d'horizon 1.

2.3.1 Modèle à facteur iid

Supposons qu'il y ait N sources de risque. On note $L_{t+1}^{(i)}$ la perte engendrée par la source i entre les dates t et $t+1$. Pour appréhender les problèmes liés à l'agrégation des divers risques, on considère le modèle suivant:

$$L_{t+1}^{(i)} = a_i + b_i Z_{t+1} + u_{t+1}^{(i)}, \quad i = 1, \dots, N \quad (2.6)$$

où (Z_t) est un processus iid de loi $\mathcal{N}(0, 1)$, inobservable, les $(u_t^{(i)})$ sont des bruits blancs indépendants entre eux et indépendants de (Z_t) , de loi $\mathcal{N}(0, \sigma_i^2)$, a_i et b_i sont des paramètres. Le processus (Z_t) s'interprète donc comme un facteur de risque commun, tandis que les $(u_t^{(i)})$ sont des risques idiosyncratiques. Dans ce modèle, les pertes de dates différentes sont indépendantes mais les pertes d'une même période liées à des risques différents sont corrélées.

²Cette partie est tirée de Monfort (2008).

La perte globale est

$$L_{t+1} = \sum_{i=1}^N L_{t+1}^{(i)} = a + bZ_{t+1} + u_{t+1},$$

où $a = \sum_{i=1}^N a_i$, $b = \sum_{i=1}^N b_i$, $u_{t+1} = \sum_{i=1}^N u_{t+1}^{(i)}$. En raison de l'indépendance, VaR conditionnelle et non conditionnelle coïncident pour ce modèle. En utilisant (2.4), la VaR associée au risque i est

$$\text{VaR}^{(i)}(\alpha) = a_i + (b_i^2 + \sigma_i^2)^{1/2} \Phi^{-1}(1 - \alpha). \quad (2.7)$$

celle associée à la perte globale est

$$\text{VaR}(\alpha) = a + (b^2 + \sigma^2)^{1/2} \Phi^{-1}(1 - \alpha), \quad (2.8)$$

où $\sigma^2 = \sum_{i=1}^N \sigma_i^2$. Le coefficient b dépend des corrélations entre les $L_{t+1}^{(i)}$ et Z_{t+1} . Plus $|b|$ est grand plus la VaR(α) est grande. On peut voir b^2 comme une mesure de la *contagion*. En particulier si $b = \sum_{i=1}^N b_i = 0$, on dit que le champ de risques est *immunisé* contre le facteur de risque commun. On a

$$\text{VaR}(\alpha) - \sum_{i=1}^N \text{VaR}^{(i)}(\alpha) = \left\{ (b^2 + \sigma^2)^{1/2} - \sum_{i=1}^N (b_i^2 + \sigma_i^2)^{1/2} \right\} \Phi^{-1}(1 - \alpha).$$

Cette différence est du signe de

$$\sum_{i \neq j} \{ b_i b_j - (b_i^2 + \sigma_i^2)^{1/2} (b_j^2 + \sigma_j^2)^{1/2} \} \leq 0,$$

l'égalité n'ayant lieu que si les bruits sont dégénérés ($\sigma_i^2 = 0, \forall i$) et si tous les b_i sont de même signe. Sauf dans ce cas, il y a donc *diversification* partielle (la partie non anticipée du risque est réduite).

Si l'on supposait à tort que les risques sont indépendants on utiliserait la VaR erronée

$$\text{VaR}^e(\alpha) = a + \left\{ \sum_{i=1}^N (b_i^2 + \sigma_i^2) \right\}^{1/2} \Phi^{-1}(1 - \alpha),$$

Cette formule conduit à une sous-estimation si et seulement si $b^2 = (\sum_{i=1}^N b_i)^2 > \sum_{i=1}^N b_i^2$. La dépendance entre les risques amène donc soit de la diversification partielle soit de la contagion.

Risques homogènes

Si toutes les sources de risque sont homogènes, c'est-à-dire si $a_i = a_0, b_i = b_0, \sigma_i = \sigma_0$ pour tout i , la VaR moyenne vaut

$$\begin{aligned}\overline{\text{VaR}}(\alpha) &= \frac{1}{N} \text{VaR}(\alpha) = a_0 + (b_0^2 + N^{-1}\sigma_0^2)^{1/2} \Phi^{-1}(1 - \alpha) \\ &< a_0 + (b_0^2 + \sigma_0^2)^{1/2} \Phi^{-1}(1 - \alpha) = \text{VaR}_t^{(i)}(\alpha).\end{aligned}$$

Lorsque N tend vers l'infini, la partie de $\overline{\text{VaR}}_t(\alpha)$ due à la perte non anticipée tend donc vers $b_0 \Phi^{-1}(1 - \alpha)$. Si $b_0 \neq 0$, il y a donc diversification partielle, même asymptotiquement, car la partie due au facteur commun ne peut être diversifiée. Si $b_0 = 0$, les risques sont indépendants et il y a diversification totale asymptotiquement.

Estimation du facteur commun

Le filtre de Kalman permet d'estimer Z_t au vu des pertes $L_j^{(i)}$, $i = 1, \dots, N$, $j = 1, \dots, t$ et en supposant les paramètres connus. Introduisons les vecteurs $\mathbf{L}_t = (L_t^{(1)}, \dots, L_t^{(N)})'$, $\mathbf{a} = (a_1, \dots, a_N)'$, $\mathbf{b} = (b_1, \dots, b_N)'$, $\mathbf{u}_t = (u_t^{(1)}, \dots, u_t^{(N)})'$. Le modèle (A.1) s'écrit

$$\mathbf{L}_t = \mathbf{a} + \mathbf{b}Z_t + \mathbf{u}_t, \quad \mathbf{u}_t \sim \mathcal{N}(0, \Sigma := \text{diag}(\sigma_1^2, \dots, \sigma_N^2)).$$

On obtient, en utilisant la formule de l'espérance conditionnelle pour un vecteur gaussien³,

$$Z_{t|t} = E(Z_t | \mathbf{L}_t) = \mathbf{b}'(\mathbf{b}\mathbf{b}' + \Sigma)^{-1}(\mathbf{L}_t - \mathbf{a}).$$

Or

$$(\mathbf{b}\mathbf{b}' + \Sigma)^{-1} = \Sigma^{-1} - \frac{\Sigma^{-1}\mathbf{b}\mathbf{b}'\Sigma^{-1}}{1 + \mathbf{b}'\Sigma^{-1}\mathbf{b}}$$

donc

$$\mathbf{b}'(\mathbf{b}\mathbf{b}' + \Sigma)^{-1} = \mathbf{b}'\Sigma^{-1} - \frac{\mathbf{b}'\Sigma^{-1}\mathbf{b}\mathbf{b}'\Sigma^{-1}}{1 + \mathbf{b}'\Sigma^{-1}\mathbf{b}} = \frac{\mathbf{b}'\Sigma^{-1}}{1 + \mathbf{b}'\Sigma^{-1}\mathbf{b}}$$

et finalement

$$Z_{t|t} = \frac{\sum_{i=1}^N b_i (L_t^{(i)} - a_i) / \sigma_i^2}{1 + \sum_{i=1}^N b_i^2 / \sigma_i^2}.$$

³Si le vecteur $(x, y)'$ est gaussien, de matrice de variance définie positive, avec $\mu_x = E(x)$, $\mu_y = E(y)$, $\Sigma_{xx} = \text{Var}(x)$, $\Sigma_{yy} = \text{Var}(y)$, $\Sigma_{xy} = \Sigma'_{yx} = \text{Cov}(x, y)$, la loi de x conditionnelle à y est la gaussienne

$$\mathcal{N}(\mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y), \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx})$$

La variance de l'erreur vaut

$$\begin{aligned} V(Z_t - Z_{t|t}) &= V(Z_t) - V(Z_{t|t}) = 1 - \mathbf{b}'(\mathbf{b}\mathbf{b}' + \Sigma)^{-1}\mathbf{b} = 1 - \frac{\mathbf{b}'\Sigma^{-1}\mathbf{b}}{1 + \mathbf{b}'\Sigma^{-1}\mathbf{b}} \\ &= \frac{1}{1 + \mathbf{b}'\Sigma^{-1}\mathbf{b}} = \frac{1}{1 + \sum_{i=1}^N b_i^2/\sigma_i^2}. \end{aligned}$$

Elle est d'autant plus petite que les ratios de type "signal-bruit" b_i^2/σ_i^2 sont grands.

2.3.2 Modèle à facteur autocorrélé

Supposons maintenant que le facteur Z_t du modèle (A.1) ait une dynamique AR(1) donnée par

$$Z_t = \rho Z_{t-1} + \sqrt{1 - \rho^2} \epsilon_t, \quad |\rho| < 1, \quad (2.9)$$

où (ϵ_t) est une suite iid de loi $\mathcal{N}(0, 1)$. Le solution stationnaire (Z_t) de ce modèle est également de loi $\mathcal{N}(0, 1)$.

A la date t on observe $(\mathbf{L}_t, \mathbf{L}_{t-1}, \dots, \mathbf{L}_1)$. Conditionnellement à cet ensemble d'information, la loi de $\mathbf{L}_{t+1}$ est la loi normale

$$\mathcal{N}(\mathbf{a} + \mathbf{b}\hat{Z}_{t+1|t}, \Sigma + \omega_{t+1|t}^2 \mathbf{b}\mathbf{b}')$$

où $\hat{Z}_{t+1|t} = E_{t+1}(Z_t)$ et $\omega_{t+1|t}^2 = V_{t+1}(Z_t)$ (espérance et variance conditionnelles à $\mathbf{L}_t, \mathbf{L}_{t-1}, \dots, \mathbf{L}_1$). Ces quantités sont obtenues récursivement à partir des équations du *filtre de Kalman*, faisant intervenir le filtrage $\hat{Z}_{t|t} = E_t(Z_t)$ de Z_t et la variance de l'erreur de filtrage, $V_t(Z_t) = \omega_{t|t}^2$:

$$\begin{aligned} \hat{Z}_{t|t} &= \hat{Z}_{t|t-1} + \mathbf{b}'(\omega_{t|t-1}^{-2}\Sigma + \mathbf{b}\mathbf{b}')^{-1}(\mathbf{L}_t - \mathbf{a} - \mathbf{b}\hat{Z}_{t-1|t}) \\ \hat{Z}_{t+1|t} &= \rho\hat{Z}_{t|t}, \quad \omega_{t|t}^2 = \omega_{t|t-1}^2 \{1 - \mathbf{b}'(\omega_{t|t-1}^{-2}\Sigma + \mathbf{b}\mathbf{b}')^{-1}\mathbf{b}\} \\ \omega_{t+1|t}^2 &= \rho^2\omega_{t|t}^2 + 1 - \rho^2, \quad \hat{Z}_{1|0} = 0, \quad \omega_{1|0}^2 = 1. \end{aligned}$$

On en déduit que la loi conditionnelle de la perte totale L_t est la normale

$$\mathcal{N}(a + b\hat{Z}_{t+1|t}, \sigma^2 + \omega_{t+1|t}^2 b^2)$$

où $a = \sum_{i=1}^N a_i$, $b = \sum_{i=1}^N b_i$ et $\sigma^2 = \sum_{i=1}^N \sigma_i^2$. On en déduit

$$\text{VaR}_{t+1}(\alpha) = a + b\hat{Z}_{t+1|t} + (\omega_{t+1|t}^2 b^2 + \sigma^2)^{1/2} \Phi^{-1}(1 - \alpha). \quad (2.10)$$

On voit que la VaR dépend ici de t sauf lorsque le coefficient de contagion $b = 0$. Dans ce cas on retrouve la VaR calculée en l'absence d'autocorrélation du facteur Z_t . Notons qu'il est possible de montrer que la variance conditionnelle $\omega_{t+1|t}^2$ converge vers 1, variance non conditionnelle de Z_t . Même asymptotiquement, la formule (2.10) reste cependant différente de (2.8) en raison de la mise à jour de l'estimation du facteur Z_t .

2.4 Autres mesures de risque standard

Bien que la VaR soit la mesure de risque couramment utilisée, le choix d'une mesure de risque adéquate n'est pas encore tranché.

2.4.1 Volatilité et moments

Dans la théorie du portefeuille de Markowitz (1952), la variance est utilisée comme mesure du risque. Dans un cadre dynamique, il pourrait donc sembler naturel de prendre comme mesure de risque la volatilité. Cette notion s'est avérée mal comprise par de nombreux praticiens. De plus, la volatilité ne tient pas compte du signe des écarts à la moyenne. Enfin, cette mesure ne vérifie pas un certain nombre de propriétés de "cohérence" que nous verrons plus loin (invariance par translation, sous-additivité).

2.4.2 Expected shortfall

L'expected shortfall (ES), ou perte anticipée, est la mesure de risque standard utilisée en assurance sous l'impulsion de Solvency 2. Cette mesure de risque très liée à la VaR, évite certaines de ses difficultés conceptuelles (voir plus loin la sous-additivité). Par ailleurs la VaR ne donne pas d'information sur la perte potentielle encourue lorsqu'elle est dépassée.

Soit $L_{t,t+h}$ telle que $EL_{t,t+h}^+ < \infty$. Dans un premier temps on suppose la loi conditionnelle de $L_{t,t+h}$ absolument continue. On définit l'ES au niveau α , ou Tailvar, comme l'espérance conditionnelle de la perte sachant que celle-ci dépasse la VaR:

$$ES_{t,h}(\alpha) := E_t[L_{t,t+h} \mid L_{t,t+h} > \text{VaR}_{t,h}(\alpha)]. \quad (2.11)$$

On a, en omettant provisoirement les indices,

$$E[L \mathbf{1}_{L > \text{VaR}(\alpha)}] = E[L \mid L > \text{VaR}(\alpha)]P[L > \text{VaR}(\alpha)].$$

Or $P[L > \text{VaR}(\alpha)] = 1 - P[L \leq \text{VaR}(\alpha)] = 1 - (1 - \alpha) = \alpha$, l'avant dernière égalité découlant de la continuité de la fonction de répartition en $\text{VaR}(\alpha)$. D'où

$$ES_{t,h}(\alpha) = \frac{1}{\alpha} E_t[L_{t,t+h} \mathbf{1}_{L_{t,t+h} > \text{VaR}_{t,h}(\alpha)}]. \quad (2.12)$$

La définition suivante résume les égalités obtenues pour l'ES et donne une extension.

Définition 2.2 Soit $L_{t,t+h}$ telle que $EL_{t,t+h}^+ < \infty$. Si la loi conditionnelle de $L_{t,t+h}$ est absolument continue, on définit l'ES au niveau de confiance α comme

$$ES_{t,h}(\alpha) = E_t[L_{t,t+h} \mid L_{t,t+h} > VaR_{t,h}(\alpha)] = \frac{1}{\alpha} E_t[L_{t,t+h} \mathbb{1}_{L_{t,t+h} > VaR_{t,h}(\alpha)}]$$

Dans le cas général on définit

$$\begin{aligned} & ES_{t,h}(\alpha) \\ &= \frac{1}{\alpha} \left\{ E_t[L_{t,t+h} \mathbb{1}_{L_{t,t+h} > VaR_{t,h}(\alpha)}] + VaR_{t,h}(\alpha)(\alpha - P_t[L_{t,t+h} > VaR_{t,h}(\alpha)]) \right\}. \end{aligned}$$

L'espérance conditionnelle $E_t[L_{t,t+h} \mid L_{t,t+h} > VaR_{t,h}(\alpha)]$, qui coïncide avec l'ES dans le cas continu, est appelé *tail-VaR*. La propriété suivante donne une caractérisation utile de l'ES.

Proposition 2.1 Soit $L_{t,t+h}$ telle que $EL_{t,t+h}^+ < \infty$. On a

$$ES_{t,h}(\alpha) = \frac{1}{\alpha} \int_0^\alpha VaR_{t,h}(u) du.$$

Preuve. Pour simplifier, on omettra les indices dans cette preuve. Remarquons d'abord que si $P[L > VaR(\alpha)] = 0$, on a $ES(\alpha) = VaR(\alpha)$ et la propriété est vérifiée car $VaR(u) = VaR(\alpha)$ pour tout $u \leq \alpha$. Supposons maintenant $P[L > VaR(\alpha)] > 0$. En utilisant le fait que L a même loi que $F^\leftarrow(U)$, où U désigne une variable de loi uniforme sur $[0, 1]$ et F la fonction de répartition de L (voir la propriété B.1), on a,

$$E[L \mathbb{1}_{L > VaR(\alpha)}] = E[F^\leftarrow(U) \mathbb{1}_{F^\leftarrow(U) > F^\leftarrow(1-\alpha)}]$$

Or l'événement $[F^\leftarrow(U) > F^\leftarrow(1-\alpha)]$ s'écrit $[U > (1-\alpha)^+]$ où

$$(1-\alpha)^+ = \inf\{x \in]0, 1[\mid F^\leftarrow(x) > F^\leftarrow(1-\alpha)\} = P[L \leq VaR]. \quad (2.13)$$

Donc

$$\begin{aligned} E[L \mathbb{1}_{L > VaR(\alpha)}] &= \int_{(1-\alpha)^+}^1 F^\leftarrow(u) du \\ &= \int_0^{1-(1-\alpha)^+} F^\leftarrow(1-u) du \\ &= \int_0^\alpha VaR(u) du - \int_{1-(1-\alpha)^+}^\alpha VaR(u) du \\ &= \int_0^{1-(1-\alpha)^+} F^\leftarrow(1-u) du \\ &= \int_0^\alpha VaR(u) du - \{\alpha - 1 + (1-\alpha)^+\} VaR(\alpha) \end{aligned}$$

En utilisant (2.13) et la définition 2.2 on obtient l'égalité cherchée.

□

Cette mesure de risque s'interprète donc, pour un niveau de confiance α , comme la moyenne de la VaR sur tous les niveaux $u \leq \alpha$. On a évidemment $ES_{t,h}(\alpha) \geq \text{VaR}_{t,h}(\alpha)$.

Par ailleurs, la caractérisation intégrale fait de $ES_{t,h}(\alpha)$ une fonction continue de α , quelle que soit la nature des variables de perte. La VaR ne vérifie pas toujours cette propriété (pour des variables de perte nulles avec probabilité 1 sur certains intervalles).

Exemple 2.4 (Cas gaussien) Si la distribution conditionnelle de la distribution de perte est la loi $\mathcal{N}(m_{t,t+h}, \sigma_{t,t+h}^2)$ alors, d'après (2.4), $\text{VaR}_{t,h}(\alpha) = m_{t,t+h} + \sigma_{t,t+h} \Phi^{-1}(1 - \alpha)$ où Φ est la f.r. de la loi $\mathcal{N}(0, 1)$. En utilisant (2.11) et en notant L^* une variable de loi $\mathcal{N}(0, 1)$ et ϕ sa densité, on a

$$\begin{aligned} ES_{t,h}(\alpha) &= m_{t,t+h} + \sigma_{t,t+h} E[L^* \mid L^* \geq \Phi^{-1}(1 - \alpha)] \\ &= m_{t,t+h} + \sigma_{t,t+h} \frac{1}{\alpha} E[L^* \mathbf{1}_{L^* \geq \Phi^{-1}(1 - \alpha)}] \\ &= m_{t,t+h} + \sigma_{t,t+h} \frac{1}{\alpha} \phi\{\Phi^{-1}(1 - \alpha)\}. \end{aligned}$$

Par exemple si $\alpha = 0.05$, l'écart-type conditionnel est multiplié par 1.65 dans la formule de la VaR et par 2.06 dans la formule de l'expected shortfall.

On a plus généralement sous l'hypothèse (2.3), d'après la proposition 2.1 et (2.4),

$$ES_{t,h}(\alpha) = m_{t,t+h} + \sigma_{t,t+h} \frac{1}{\alpha} \int_0^\alpha F_h^{\leftarrow}(1 - u) du. \quad (2.14)$$

Les liens entre VaR et expected shortfall peuvent être étudiés de manière plus détaillée (voir Gouriéroux et Liu, 2006). Les formules (2.4) et (2.14) diffèrent par le ratio des coefficients en facteur de l'écart-type conditionnel:

$$L(\alpha) := \frac{1}{\alpha F_h^{\leftarrow}(1 - \alpha)} \int_0^\alpha F_h^{\leftarrow}(1 - u) du. \quad (2.15)$$

Le tableau 2.1 présente les valeurs de la VaR et de l'ES pour quatre distributions ainsi que la valeur de $L(\alpha)$. Ce coefficient est toujours plus grand que 1 mais peut être très différent selon les distributions. Il tend vers 1 lorsque α tend vers 0 dans le cas de la loi uniforme et de la loi double-exponentielle (Laplace). En revanche,




Figure 2.2: Fonctions de densité (à gauche) et fonctions quantiles (à droite) pour les lois de Pareto de paramètre $a = 3, b = 1$ (en rouge) et $a = 4, b = 1$ (en noir).

il est indépendant de α pour la loi de Pareto et on peut montrer que cette loi est la seule, pour des variables positives, avec un coefficient $L(\alpha)$ constant (voir Gouriéroux et Liu, Proposition 1, 2006).

La figure 2.2 présente deux exemples de fonctions de densité et quantile pour la loi de Pareto.

2.4.3 Mesures de distorsion

Dans cette partie on suppose pour simplifier que la fonction de répartition F_h de loi de perte est continue et strictement croissante. On supprime les indices t et h pour alléger les notations. D'après la propriété 2.1, l'ES s'écrit (en omettant les indices)

$$ES(\alpha) = \int_0^1 F^{-1}(1-u) \mathbb{1}_{[0,\alpha]}(u) \frac{1}{\alpha} du,$$

le terme $\mathbb{1}_{[0,\alpha]} \frac{1}{\alpha}$ s'interprétant comme la densité de la loi uniforme sur $[0, \alpha]$. Plus généralement, on appelle *mesure de distorsion* (DRM, distortion risk measure) le nombre

$$r(F; G) = \int_0^1 F^{-1}(1-u) dG(u),$$

où G est une fonction de répartition sur $[0, 1]$, appelée *fonction de distorsion*, et F est la distribution de perte. L'introduction d'une loi de probabilité sur les niveaux de confiance est parfois interprétée en termes d'optimisme ou de pessimisme par rapport au risque. Si G admet une densité g et si g est croissante sur $[0, 1]$, c'est-à-dire si G est convexe, les quantiles $F^{-1}(1-u)$ sont affectés d'un poids d'autant plus grand que u est grand: les grands risques sont donc peu pris en compte. À l'inverse, si g est décroissante, ces risques extrêmes ont la plus forte pondération.

La VaR au niveau de confiance α est une mesure de distorsion, obtenue en prenant pour G la masse de Dirac en α . Comme nous l'avons vu, l'expected shortfall correspond à la densité g constante sur $[0, \alpha]$: il s'agit d'une moyenne sur tous les niveaux de confiance inférieurs à α .

On a, par intégration par parties, puis changement de variable ($u \mapsto 1 - u$)

$$\begin{aligned} r(F; G) &= \int_0^{1-F(0)} F^{-1}(1-u) dG(u) + \int_{1-F(0)}^1 F^{-1}(1-u) d[G(u) - 1] \\ &= - \int_0^{1-F(0)} G(u) dF^{-1}(1-u) - \int_{1-F(0)}^1 [G(u) - 1] dF^{-1}(1-u) \\ &= \int_{F(0)}^1 G(1-u) dF^{-1}(u) + \int_0^{F(0)} [G(1-u) - 1] dF^{-1}(u). \end{aligned} \quad (2.16)$$

Par suite, un nouveau changement de variable ($u = F(x)$) conduit à la formule

$$r(F; G) = \int_0^{+\infty} G\{S(x)\} dx - \int_{-\infty}^0 [1 - G\{S(x)\}] dx \quad (2.17)$$

où $S(x) = 1 - F(x) = P[L > x]$ (appelée fonction de survie dans la littérature sur les modèles de durée). Introduisant la variable aléatoire $L^* = L^*(F; G)$ telle que $S_{L^*}(x) = G\{S(x)\}$, il vient, d'après une caractérisation de l'espérance ⁴,

$$r(F; G) = E(L^*). \quad (2.18)$$

L'interprétation est la suivante: la fonction de survie S initiale est remplacée par une fonction de survie $G(S)$ (qui donne plus de poids aux grandes valeurs positives lorsque G est concave). La mesure de risque est alors calculée comme l'espérance pour cette nouvelle loi.

En particulier, pour une variable positive ($F(0) = 0$) on a les formules

$$r(F; G) = \int_0^1 G(1-u) dF^{-1}(u) = \int_0^{+\infty} G\{S(x)\} dx = E(L^*),$$

où L^* est positive. La première égalité montre que F^{-1} et G jouent des rôles symétriques.

On construit des familles de mesures de risque en paramétrant la mesure de distorsion

$$r_p(F; G) = \int_0^1 F^{-1}(1-u) dG_p(u),$$

où le paramètre reflète le niveau de confiance, c'est-à-dire le plus ou moins grand optimisme face au risque.

⁴Pour une variable X intégrable on a $E(X) = \int_0^\infty P(X > x) dx - \int_{-\infty}^0 P[X < x] dx$ (voir Billingsley (1995), *Probability and measure*, 3rd edition, John Wiley).

Exemple 2.5 (DRM à hasard proportionnel.) On prend $G_p(u) = u^p$, où $p \in]0, +\infty[$. Lorsque $p < 1$, G est concave, les pertes extrêmes sont donc surpondérées. D'après (2.16) et (2.17),

$$\begin{aligned} r_p(F; G) &= \int_0^1 F^{-1}(1-u) p u^{p-1} du \\ &= \int_{F(0)}^1 (1-u)^p dF^{-1}(u) + \int_0^{F(0)} [(1-u)^p - 1] dF^{-1}(u) \\ &= \int_0^{+\infty} \{1 - F(x)\}^p dx - \int_{-\infty}^0 [1 - \{1 - F(x)\}^p] dx \\ &= E(L_p) \end{aligned}$$

où L_p est une variable de fonction de survie

$$P[L_p > x] = \{1 - F(x)\}^p = \{P[L > x]\}^p.$$

On parle de "hasard proportionnel" car la fonction de hasard, définie comme l'opposé de la dérivée du logarithme de la fonction de survie ⁵, des variables L_p et L sont proportionnelles:

$$\frac{-\partial}{\partial x} \log P[L_p > x] = p \frac{-\partial}{\partial x} \log P[L > x] = \frac{p f(x)}{P[L > x]}$$

en notant f la densité de F .

Exemple 2.6 (DRM exponentielle.) On prend $G_p(u) = \frac{1-e^{-pu}}{1-e^{-p}}$, où $p \in]0, +\infty[$. On a

$$r_p(F; G) = \int_0^1 F^{-1}(1-u) \frac{p e^{-pu}}{1-e^{-p}} du.$$

La fonction g est décroissante quel que soit p , ce qui correspond à nouveau à une surpondération des pertes extrêmes.

Remarque 2.4 Il peut être intéressant d'examiner la sensibilité de la mesure de distorsion par rapport au paramètre p . Lorsque $r_p(F; G)$ est une fonction différentiable de p , il suffit de calculer la dérivée $\partial r_p(F; G)/\partial p$.

Pour l'expected shortfall, on a d'après la proposition 2.1

$$\frac{\partial}{\partial \alpha} \text{ES}(\alpha) = \frac{1}{\alpha} \{\text{VaR}(\alpha) - \text{ES}(\alpha)\}.$$

⁵Dans les modèles de durée, la fonction de hasard au point x s'interprète comme la probabilité de disparaître à la date x sachant que l'on a atteint cette date.

Table 2.1: VaR et ES pour les lois uniforme, double-exponentielle, de Pareto et gaussienne standard, et sensibilités par rapport à α . Le ratio $L(\alpha)$ est défini en (2.15).

	$\mathcal{U}_{[a,b]}$	$\mathcal{N}(0,1)$	Laplace (λ), $\lambda > 0$	Pareto (a, b), $a > 1$
$F(x)$	$\frac{x-a}{b-a} \mathbb{1}_{[a,b]}(x)$	$\Phi(x)$	$1 - 0.5e^{-\lambda x}$ (pour $x > 0$)	$(1 - (\frac{x}{b})^{-a}) \mathbb{1}_{x>b}$
$\text{VaR}(\alpha)$	$a + (b-a)(1-\alpha)$	$\Phi^{-1}(1-\alpha)$	$-\frac{1}{\lambda} \log(2\alpha)$	$b\alpha^{-1/a}$
$\frac{\partial \text{VaR}(\alpha)}{\partial \alpha}$	$a - b$	$\frac{-1}{\phi\{\Phi^{-1}(1-\alpha)\}}$	$-\frac{1}{\lambda\alpha}$	$\frac{-b}{a} \alpha^{-(a+1)/a}$
$\text{ES}(\alpha)$	$a + (b-a)(1 - \frac{\alpha}{2})$	$\frac{1}{\alpha} \phi\{\Phi^{-1}(1-\alpha)\}$	$\frac{1}{\lambda}(1 - \log(2\alpha))$	$\frac{ba}{a-1} \alpha^{-1/a}$
$\frac{\partial \text{ES}(\alpha)}{\partial \alpha}$	$\frac{a-b}{2}$	$\frac{1}{\alpha} \Phi^{-1}(1-\alpha)$ $-\frac{1}{\alpha^2} \phi\{\Phi^{-1}(1-\alpha)\}$	$-\frac{1}{\lambda\alpha}$	$\frac{-b}{a-1} \alpha^{-(a+1)/a}$
$L(\alpha)$	$\frac{a+(b-a)(1-\alpha/2)}{a+(b-a)(1-\alpha)}$	$\frac{\phi\{\Phi^{-1}(1-\alpha)\}}{\alpha\Phi^{-1}(1-\alpha)}$	$1 - \frac{1}{\log(2\alpha)}$	$\frac{a}{a-1}$

Cette dérivée est négative ce qui confirme que l'ES augmente lorsque α diminue (évident d'après (2.11)). Le tableau 2.1 donne quelques exemples de sensibilités par rapport à $p = \alpha$, pour la VaR et l'ES, et pour plusieurs lois F , classées par queues de distribution croissantes. Notons que lorsque la loi de perte n'est pas continue, la VaR n'est pas continue et a fortiori différentiable pour toute valeur de α . En revanche l'ES reste continu en α . Ainsi, quelle que soit la distribution de perte sous-jacente, cette mesure de risque garantit qu'un petit changement du niveau de confiance ne modifiera pas fortement le niveau de réserves. Il est parfois nécessaire d'introduire des lois de perte non continues pour les portefeuilles contenant des dérivés (mélanges de lois discrètes et continues).

2.5 Sensibilité par rapport à la composition de portefeuille

On examine dans cette partie comment les différents actifs d'un portefeuille influent sur le risque global.

Soit un portefeuille de prix $p_t = a'P_t$, où $a, P_t \in \mathbb{R}^d$.

Supposons dans un premier temps les variations de prix iid gaussiennes, $\Delta P_t \sim \text{iid } \mathcal{N}(m, \Sigma)$. Rappelons que $L_{t,t+h} = -a' \sum_{i=1}^h \Delta P_{t+i}$. D'après la formule (2.5), la valeur à risque est donnée par

$$\text{VaR}_{t,h}(\alpha) = -a'mh + \sqrt{a'\Sigma a} \sqrt{h} \Phi^{-1}(1-\alpha) := \text{VaR}_{t,h}(a, \alpha). \quad (2.19)$$

On a donc

$$\begin{aligned}
\frac{\partial \text{VaR}_{t,h}(a, \alpha)}{\partial a} &= -mh + \frac{\Sigma a}{\sqrt{a' \Sigma a}} \sqrt{h} \Phi^{-1}(1 - \alpha) \\
&= -mh + \frac{\Sigma a}{a' \Sigma a} \{ \text{VaR}_{t,h}(a, \alpha) + a' mh \} \\
&= -E[\Delta_h P_{t+h} \mid L_{t,t+h} = \text{VaR}_{t,h}(a, \alpha)]
\end{aligned} \tag{2.20}$$

en posant $\Delta_h P_{t+h} = P_{t+h} - P_t$ et en utilisant la note de bas de page ³. Notons que la formule (2.20) est brevetée par Garman et appelée *delta-VaR*. On constate que cette dérivée est une fonction affine et indépendante de α de la valeur à risque. Elle fournit la contribution marginale au risque de chacun des actifs composant le portefeuille.

On a de même

$$\begin{aligned}
\frac{\partial^2 \text{VaR}_{t,h}(a, \alpha)}{\partial a \partial a'} &= \frac{\sqrt{h} \Phi^{-1}(1 - \alpha)}{\sqrt{a' \Sigma a}} \left(\Sigma - \frac{\Sigma a a' \Sigma}{a' \Sigma a} \right) \\
&= \frac{\Phi^{-1}(1 - \alpha)}{\sqrt{h} \sqrt{a' \Sigma a}} V[\Delta_h P_{t+h} \mid L_{t,t+h} = \text{VaR}_{t,h}(a, \alpha)] \tag{2.21}
\end{aligned}$$

On constate que la dérivée seconde est semi-définie positive. Ainsi, la fonction $a \mapsto \text{VaR}_{t,h}(a, \alpha)$ est convexe **dans le cas gaussien**. Si a et a^* caractérisent deux portefeuilles on a donc

$$\text{VaR}_{t,h}\left\{\frac{1}{2}(a + a^*), \alpha\right\} \leq \frac{1}{2}\{\text{VaR}_{t,h}(a, \alpha) + \text{VaR}_{t,h}(a^*, \alpha)\}$$

ce qui signifie que l'on a intérêt à la diversification.

Ce résultat reste-t-il valable dans le cas général? Nous allons voir que non. Les formules obtenues pour les dérivées peuvent être étendues au cas de distributions non gaussiennes. On a $L_{t,t+h} = -a' \Delta_h P_{t+h}$. Supposons que la loi conditionnelle de $\Delta_h P_{t+h}$ soit absolument continue. La VaR au niveau α de ce portefeuille est caractérisée par la relation

$$P_t[X + a_1 Y > \text{VaR}_{t,h}(a, \alpha)] = \alpha, \quad X = -\sum_{i=2}^d a_i \Delta_h P_{i,t+h}, \quad Y = -\Delta_h P_{1,t+h}.$$

Le lemme B.1 montre que

$$\frac{\partial \text{VaR}_{t,h}(a, \alpha)}{\partial a_1} = -E_t[\Delta_h P_{1,t+h} \mid L_{t,t+h} = \text{VaR}_{t,h}(a, \alpha)].$$

Par suite, on obtient la même formule que dans le cas gaussien:

$$\frac{\partial \text{VaR}_{t,h}(a, \alpha)}{\partial a} = -E_t[\Delta_h P_{t+h} \mid L_{t,t+h} = \text{VaR}_{t,h}(a, \alpha)].$$

Soit g_a la densité conditionnelle de $L_{t,t+h} = -a' \Delta_h P_{t+h}$. On montre que les dérivées secondes sont données par

$$\begin{aligned} \frac{\partial^2 \text{VaR}_{t,h}(a, \alpha)}{\partial a \partial a'} &= - \left(\frac{\partial}{\partial z} \log g_a(z) \right)_{z=\text{VaR}_{t,h}(a, \alpha)} V_t[\Delta_h P_{t+h} \mid L_{t,t+h} = \text{VaR}_{t,h}(a, \alpha)] \\ &\quad - \left(\frac{\partial}{\partial z} V_t[\Delta_h P_{t+h} \mid L_{t,t+h} = z] \right)_{z=\text{VaR}_{t,h}(a, \alpha)} \end{aligned}$$

(voir Gouriéroux, Laurent, Scaillet (2000)). La dérivée seconde fait apparaître deux effets. Le premier terme est un effet de volatilité, dont l'impact dépend de la queue de la distribution de perte. Le second terme est un effet d'hétéroscédasticité qui disparaît dans le cas gaussien⁶.

La forme de la dérivée seconde permet de discuter les propriétés de convexité de la VaR comme fonction de la composition du portefeuille. La convexité est une propriété souhaitable d'une mesure de risque car elle favorise la diversification. Dans la formule de la dérivée seconde, le premier terme est une matrice définie positive à condition que la densité g_a soit décroissante pour les grandes valeurs positives. Le second terme peut avoir un signe positif ou négatif. Dans le cas gaussien il disparaît et la convexité est bien respectée.

2.6 Mesures de risque cohérentes

La VaR est souvent critiquée pour ne pas vérifier, pour toute distribution des variations de prix, la propriété de convexité par rapport à la composition de portefeuille. Ceci signifie que le risque d'un portefeuille, lorsqu'il est mesuré par la VaR, peut être supérieur au risque de la somme de chacune de ses composantes (même lorsque ces composantes sont indépendantes, à l'exception du cas gaussien). La gestion du risque avec la VaR n'incite donc pas nécessairement à la diversification. De plus, comme nous l'avons vu, la VaR ne mesure pas la sévérité des pertes encourues.

⁶On retrouve bien (2.21) dans ce cas car

$$\left(\frac{-\partial}{\partial z} \log g_a(z) \right)_{z=\text{VaR}_{t,h}(a, \alpha)} = \left(\frac{z + a' m h}{a' \Sigma a h} \right)_{z=\text{VaR}_{t,h}(a, \alpha)} = \frac{\text{VaR}_{t,h}(a, \alpha) + a' m h}{a' \Sigma a h} = \frac{\Phi^{-1}(1 - \alpha)}{(a' \Sigma a h)^{1/2}}.$$

En réponse à ces critiques, des auteurs ont essayé de définir des concepts de mesures de risque *cohérentes*. Artzner, Delbaen, Eber et Heath (1999) proposent la définition suivante.

Définition 2.3 Soit $\mathcal{L}$ un ensemble de variables aléatoires de pertes réelles définies sur un espace mesurable $(\Omega, \mathcal{A})$. On suppose que $\mathcal{L}$ contient les constantes et est stable pour l'addition et la multiplication par un scalaire. Une application $\rho : \mathcal{L} \mapsto \mathbb{R}$ est appelée mesure de risque cohérente si elle est:

1. *monotone*: $\forall L_1, L_2 \in \mathcal{L}, \quad L_1 \leq L_2 \Rightarrow \rho(L_1) \leq \rho(L_2)$.
2. *sous-additive*: $\forall L_1, L_2 \in \mathcal{L}, \quad \rho(L_1 + L_2) \leq \rho(L_1) + \rho(L_2)$.
3. *positivement homogène*: $\forall L \in \mathcal{L}, \forall \lambda \geq 0, \quad \rho(\lambda L) = \lambda \rho(L)$.
4. *invariante par translation*:
 $\forall L \in \mathcal{L}, \forall c \in \mathbb{R}, \quad \rho(L + c) = \rho(L) + c$.

Remarque 2.5 Cette caractérisation axiomatique a été initialement introduite avec un espace probabilisé fini par Artzner, Delbaen, Eber et Heath (1999), puis étendue par Delbaen (2002). Dans ce dernier papier il est montré que l'on ne peut prendre un ensemble $\mathcal{L}$ trop gros, par exemple l'ensemble de toutes les variables aléatoires absolument continues, pour qu'il existe des mesures de risque cohérentes.

Remarque 2.6 Cette définition est parfois énoncée pour des variables de profit et non de pertes, c'est-à-dire pour $-L$ au lieu de L ; il faut alors prendre garde de modifier la première inégalité dans la propriété 1 et de changer c en $-c$ dans le membre de droite de la dernière égalité.

Des conséquences immédiates de la définition sont les suivantes:

1. $\rho(0) = 0$, en écrivant la propriété d'homogénéité avec $L = 0$. Plus généralement $\rho(c) = c$ pour toutes les constantes c (si la perte est c avec certitude, il faut provisionner c).
2. Si $L \geq 0$, alors $\rho(L) \geq 0$. Si la perte est certaine, il faut provisionner.
3. $\rho(L - \rho(L)) = 0$, i.e. le montant déterministe $\rho(L)$ annule le risque de L .

Ces contraintes sont en défaut pour la plupart des mesures de risque utilisées en finance. Ainsi la variance, ou plus généralement toute mesure fondée sur les moments centrés de la distribution de perte, ne vérifie pas, par exemple, la propriété de monotonie. L'espérance définit une mesure de risque cohérente (mais peu intéressante). La VaR vérifie toutes les propriétés à l'exception de celle de sous-additivité. Pour des variables gaussiennes (dépendantes ou indépendantes) la propriété est vérifiée mais l'exemple suivant montre que la sous-additivité peut être en défaut pour des variables continues et indépendantes.

Exemple 2.7 (Défaut de sous-additivité de la VaR) Soit L_1 et L_2 deux variables indépendantes de loi de Pareto, de densité $f(x) = (2+x)^{-2} \mathbb{1}_{x>-1}$. La fonction de répartition de cette loi est $F(x) = (1 - (2+x)^{-1}) \mathbb{1}_{x>-1}$ donc la VaR au niveau α est $\text{VaR}(\alpha) = \alpha^{-1} - 2$. On vérifie, par exemple avec Mathematica, que

$$P[L_1 + L_2 \leq x] = 1 - \frac{2}{4+x} - \frac{2 \log(3+x)}{(4+x)^2}, \quad x > -2.$$

Donc

$$P[L_1 + L_2 \leq 2\text{VaR}(\alpha)] = 1 - \alpha - \frac{\alpha^2}{2} \log\left(\frac{2-\alpha}{\alpha}\right) < 1 - \alpha.$$

Donc $\text{VaR}_{L_1+L_2}(\alpha) > \text{VaR}_{L_1}(\alpha) + \text{VaR}_{L_2}(\alpha) = 2\text{VaR}_{L_1}(\alpha), \forall \alpha \in]0, 1[$. Par exemple pour $\alpha = 0.01$ on trouve $\text{VaR}_{L_1}(0.01) = 98$ et, numériquement, $\text{VaR}_{L_1+L_2}(0.01) \approx 203.2$.

La propriété suivante montre que l'ES vérifie en particulier la sous-additivité, ce qui explique son succès pour la mesure du risque.

Proposition 2.2 *L'ES est une mesure de risque cohérente au sens de la définition 2.3.*

Preuve. Les propriétés de monotonie, d'homogénéité et d'invariance découlent de (2.11) et de ces propriétés pour la VaR. Pour la sous-additivité, on se contentera de donner la preuve pour des variables absolument continues. Pour L_i telle que $EL_i^+ < \infty$, $i = 1, 3$, notons $\text{VaR}_i(\alpha)$ la valeur at risk au niveau α et $ES_i(\alpha) = \alpha^{-1} E[L_i \mathbb{1}_{L_i \geq \text{VaR}_i(\alpha)}]$ l'ES. Pour $L_3 = L_1 + L_2$ on a

$$\begin{aligned} & \alpha \{ES_1(\alpha) + ES_2(\alpha) - ES_3(\alpha)\} \\ &= E[L_1(\mathbb{1}_{L_1 \geq \text{VaR}_1(\alpha)} - \mathbb{1}_{L_3 \geq \text{VaR}_3(\alpha)})] + E[L_2(\mathbb{1}_{L_2 \geq \text{VaR}_1(\alpha)} - \mathbb{1}_{L_3 \geq \text{VaR}_3(\alpha)})]. \end{aligned}$$

Notons que

$$(L_1 - \text{VaR}_1(\alpha))(\mathbb{1}_{L_1 \geq \text{VaR}_1(\alpha)} - \mathbb{1}_{L_3 \geq \text{VaR}_3(\alpha)}) \geq 0$$

car les deux parenthèses sont de même signe. Par suite

$$\begin{aligned} \alpha\{ES_1(\alpha) + ES_2(\alpha) - ES_3(\alpha)\} &\geq VaR_1(\alpha)E[\mathbb{1}_{L_1 \geq VaR_1(\alpha)} - \mathbb{1}_{L_3 \geq VaR_3(\alpha)}] \\ &\quad + VaR_2(\alpha)E[\mathbb{1}_{L_2 \geq VaR_2(\alpha)} - \mathbb{1}_{L_3 \geq VaR_3(\alpha)}] \\ &= 0. \end{aligned}$$

La propriété est donc démontrée.

□

Remarque 2.7 On peut montrer (voir Kusuoka (2001), Acerbi et Tasche (2002)) que l'ES est la plus petite mesure de risque majorant la VaR qui soit cohérente et ne dépendant que de la loi de perte.

Remarque 2.8 On peut montrer (voir Wang and Dhaene (1998)) que les mesures de distorsion de risque avec G concave vérifient la propriété de sous-additivité.

Les axiomes suivants ont été introduits initialement pour l'analyse des risques en assurance (voir Wang, Young et Panjer, 1997).

1. *Dépendance par rapport à la loi: $\rho(L)$ ne dépend que de la loi de L .*
2. *Additivité pour risques comonotones: $\forall L_1, L_2 \in \mathcal{L}, \rho(L_1 + L_2) = \rho(L_1) + \rho(L_2)$ dès que L_1 et L_2 sont fonctions croissantes d'une même variable Z .*

La comonotonie peut s'interpréter de la manière suivante: si L_1 et L_2 sont des pertes comonotones, elles évoluent simultanément. Plus précisément on montre qu'elles sont comonotones si et seulement si

$$[L_1(\omega) - L_1(\omega^*)][L_2(\omega) - L_2(\omega^*)] \geq 0, \quad \text{pour presque tout } (\omega, \omega^*) \in \Omega^2.$$

Il n'y a donc pas de possibilité de diversification lorsqu'on agrège les portefeuilles correspondant à ces pertes.

Proposition 2.3 *La VaR et l'ES sont des mesures de risque (i) monotones, (ii) positivement homogènes, (iii) invariantes par translation, (iv) dépendantes de la loi et (v) additives pour risques comonotones.*

Preuve. Les propriétés (i)-(iv) sont évidentes. Nous nous contenterons de vérifier (v) dans le cas où $L_i = f_i(Z)$ avec f_i strictement croissante, pour $i = 1, 2$ et en supposant la fonction de répartition de Z strictement croissante. La fonction de répartition des variables L_i est alors $F_{L_i} = F_Z \circ f_i^{-1}$. Donc la VaR de la variable L_i au niveau α est $\text{VaR}_i(\alpha) = F_{L_i}^{-1}(1 - \alpha) = f_i \circ F_Z^{-1}(1 - \alpha)$. Par suite

$$\text{VaR}_1(\alpha) + \text{VaR}_2(\alpha) = (f_1 + f_2) \circ F_Z^{-1}(1 - \alpha)$$

qui n'est autre que le quantile de $L_1 + L_2 = (f_1 + f_2)(Z)$. La propriété (v) est donc montrée, dans ce cas, pour la VaR et elle en découle pour l'ES.

□

Notons que la VaR ne dépend que d'une partie de la distribution de perte: deux lois très différentes peuvent conduire à la même VaR pour un niveau α donné (voir la figure 2.1). Ce point, avec l'absence de la propriété de sous-additivité, fait de la VaR une mesure de risque très critiquée (voir par exemple Tasche, 2002).

Chapter 3

Estimation

La littérature statistique sur les mesures de risque (VaR, Expected shortfall...) s'est longtemps cantonnée à l'estimation des mesures non conditionnelles. De nombreuses approches existent, dépendant fortement des hypothèses et modèles retenus (dépendance ou indépendance des observations, méthodes paramétriques vs non paramétriques).

Nous commençons par considérer l'estimation de la fonction de répartition dans le cas iid.

3.1 Propriétés de la fonction de répartition empirique

Soit $X_1, \dots, X_n$ un échantillon de variables iid de loi F .

Pour estimer $F(x)$ on peut utiliser la *fonction de répartition empirique* $F_n(x)$ définie par

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq x}.$$

On a les propriétés suivantes.

1. Pour x fixé, $nF_n(x)$ suit la loi binomiale d'espérance $nF(x)$ et de variance $nF(x)(1 - F(x))$.
2. Par la loi forte des grands nombres

$$F_n(x) \rightarrow F(x) \quad p.s. \quad \text{quand } n \rightarrow \infty.$$

Le théorème de Glivenko-Cantelli montre que la convergence est uniforme:

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \rightarrow 0 \quad p.s. \quad \text{quand } n \rightarrow \infty.$$

3. Pour x fixé, le TCL donne

$$\sqrt{n}\{F_n(x) - F(x)\} \xrightarrow{d} \mathcal{N}(0, F(x)(1 - F(x))). \quad (3.1)$$

4. Pour $x_1 < x_2$ fixés, on a $\text{Cov}(\mathbb{1}_{X_i \leq x_1}, \mathbb{1}_{X_i \leq x_2}) = F(x_1)(1 - F(x_2))$. Donc par le TCL

$$\begin{aligned} & \sqrt{n} \begin{pmatrix} F_n(x_1) - F(x_1) \\ F_n(x_2) - F(x_2) \end{pmatrix} \\ \Rightarrow & \mathcal{N} \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} F(x_1)(1 - F(x_1)) & F(x_1)(1 - F(x_2)) \\ F(x_1)(1 - F(x_2)) & F(x_2)(1 - F(x_2)) \end{pmatrix} \right). \end{aligned}$$

Soit $(G(x))_{x \in \mathbb{R}}$ un processus gaussien centré de fonction de covariance

$$\text{Cov}(G(x_1), G(x_2)) = F(x_1)(1 - F(x_2)), \quad x_1 < x_2.$$

Une extension du résultat précédent montre qu'au sens des distributions fini-dimensionnelles

$$\sqrt{n}(F_n(x) - F(x)) \Rightarrow G(x). \quad (3.2)$$

Soit $\{W(t), t \geq 0\}$ le mouvement Brownien standard et soit le processus $\{B(t), t \in [0, 1]\}$, appelé *pont Brownien*, défini par

$$B(t) = W(t) - tW(1), \quad 0 \leq t \leq 1.$$

Alors B est un processus gaussien tel que $B(0) = B(1) = 0$ et $E(B(t)) = 0$. De plus, puisque $\text{Cov}(W(t_1), W(t_2)) = t_1 \wedge t_2$,

$$\text{Cov}(B(t_1), B(t_2)) = t_1(1 - t_2), \quad 0 \leq t_1 < t_2 \leq 1.$$

Par suite, si F est la fonction de répartition de la loi uniforme sur $[0, 1]$, G défini en (3.2) est le pont Brownien. De plus, G peut s'exprimer en fonction du pont Brownien. En effet les processus $\{G(x)\}$ et $\{B(F(x))\}$ ont la même fonction d'autocovariance. Par suite, au sens de la convergence des distributions fini-dimensionnelles,

$$\sqrt{n}(F_n(x) - F(x)) \Rightarrow B(F(x)). \quad (3.3)$$

On peut montrer que cette convergence est en fait une convergence faible (Billingsley, 1968).

Ce résultat peut être utilisé pour tester que la loi des observations est F . on introduit la statistique de Kolmogorov-Smirnov

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F(x)|$$

et sous l'hypothèse nulle (loi F) et si F est continue, on montre que

$$\sqrt{n}D_n \Rightarrow \sup_{x \in [0,1]} |B(x)|.$$

(voir par exemple Resnik, 1994¹). Ce résultat est très intéressant car la loi asymptotique est indépendante de la distribution des observations.

3.2 Fonction quantile empirique

Ayant défini la fonction de répartition empirique $F_n(x)$, on appelle *fonction quantile empirique* la fonction $\hat{F}_n^{\leftarrow}$ définie par

$$\hat{F}_n^{\leftarrow}(\alpha) = \inf\{x \in \mathbb{R} \mid F_n(x) \geq \alpha\}, \quad 0 < \alpha < 1.$$

Pour simplifier les notations on posera, lorsqu'il n'y a pas de doute sur la loi considérée,

$$\xi_\alpha = F^{\leftarrow}(\alpha) \quad \text{et} \quad \xi_{n,\alpha} = \hat{F}_n^{\leftarrow}(\alpha).$$

3.2.1 Calcul des quantiles empiriques

Il existe plusieurs façons d'obtenir la fonction quantile empirique.

Calcul par classification

On définit l'*échantillon ordonné*

$$X_{1,n} = \min(X_1, \dots, X_n) \leq X_{2,n} \leq \dots \leq X_{n,n} = \max(X_1, \dots, X_n).$$

Lorsque F est continue, les égalités surviennent avec une probabilité nulle et peuvent être négligées. On peut donc supposer dans ce cas $X_{1,n} < \dots < X_{n,n}$ et on a alors

$$\xi_{n,\alpha} = X_{k,n}, \quad \text{pour} \quad \frac{k-1}{n} < \alpha \leq \frac{k}{n}. \quad (3.4)$$

¹ *Adventures in Stochastic Processes*, Birkhäuser, Berlin.

Calcul par minimisation

La méthode suivante paraît moins directe mais elle fournit une généralisation intéressante, la régression quantile, que nous verrons plus loin. On sait que la moyenne empirique est l'estimateur des MCO dans la régression des X_i sur la constante 1. Elle vérifie

$$\bar{X} = \arg \min_{z \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n (X_i - z)^2.$$

On obtient de même le quantile empirique de niveau $\alpha \in]0, 1[$ comme solution de

$$\xi_{n,\alpha} = \arg \min_{z \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n \rho_\alpha(X_i - z) := \arg \min_{z \in \mathbb{R}} f_{n,\alpha}(z) \quad (3.5)$$

où

$$\rho_\alpha(u) = \alpha u^+ + (1 - \alpha)(-u)^+ = u(\alpha - \mathbb{1}_{u < 0}).$$

La fonction $f_{n,\alpha}$ est positive, linéaire par morceaux, convexe, comme somme de fonctions convexes, donc continue, et tend vers $+\infty$ lorsque z tend vers $\pm\infty$. Il existe en général une unique solution à (3.5), sauf lorsque $n\alpha$ est entier où il existe deux solutions: le quantile empirique correspond alors à la plus petite des deux. En remarquant que $\partial \rho_\alpha(u)/\partial u^- = \alpha \mathbb{1}_{u > 0} + (\alpha - 1) \mathbb{1}_{u \leq 0}$ et $\partial \rho_\alpha(u)/\partial u^+ = \alpha \mathbb{1}_{u \geq 0} + (\alpha - 1) \mathbb{1}_{u < 0}$, on voit que la fonction $f_{n,\alpha}$ admet en tout point une dérivée à droite et une dérivée à gauche (qui coïncident sauf aux points X_i) données par:

$$\frac{\partial f_{n,\alpha}}{\partial z^+}(z) = \frac{-1}{n} \sum_{i=1}^n \alpha \mathbb{1}_{X_i - z > 0} + (\alpha - 1) \mathbb{1}_{X_i - z \leq 0} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq z} - \alpha, \quad (3.6)$$

$$\frac{\partial f_{n,\alpha}}{\partial z^-}(z) = \frac{-1}{n} \sum_{i=1}^n \alpha \mathbb{1}_{X_i - z \geq 0} + (\alpha - 1) \mathbb{1}_{X_i - z < 0} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i < z} - \alpha, \quad (3.7)$$

Le minimum $\xi_{n,\alpha}$ est caractérisé par les conditions

$$\frac{\partial f_{n,\alpha}}{\partial z^+}(\xi_{n,\alpha}) \geq 0, \quad \frac{\partial f_{n,\alpha}}{\partial z^-}(\xi_{n,\alpha}) < 0. \quad (3.8)$$

Il est facile de voir que l'on retrouve la caractérisation (3.4).

3.2.2 Propriétés asymptotiques

La convergence forte de $\hat{F}_n^{\leftarrow}(\alpha)$ vers $F^{\leftarrow}(\alpha)$ résulte directement de la convergence uniforme de la fonction de répartition empirique (théorème de Glivenko-Cantelli).

La loi asymptotique des quantiles empiriques dans le cas iid est donnée par le résultat suivant.

Théorème 3.1 Soit $X_1, \dots, X_n$ un échantillon de variables iid de loi absolument continue de densité f . Alors, si $\alpha \in]0, 1[$ et $f(\xi_\alpha) > 0$,

$$\sqrt{n}(\xi_{n,\alpha} - \xi_\alpha) \xrightarrow{d} \mathcal{N}(0, \omega_\alpha^2), \quad \omega_\alpha^2 = \frac{\alpha(1-\alpha)}{f^2(\xi_\alpha)}.$$

Preuve: On utilise la caractérisation des quantiles (3.5), comme minimum d'une fonction convexe. La dérivée de $f_{n,\alpha}$ est donc strictement négative en tout $z < \xi_{n,\alpha}$ (ou les dérivées à gauche et à droite si z coïncide avec l'un des X_i) et positive ou nulle pour les $z \geq \xi_{n,\alpha}$. On a donc, d'après (3.6)-(3.7), pour tout réel ϵ

$$\begin{aligned} P[\sqrt{n}(\xi_{n,\alpha} - \xi_\alpha) > \epsilon] &= P[f'_{n,\alpha}(\xi_\alpha + \epsilon/\sqrt{n}) < 0] \\ &= P\left[\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i < \xi_\alpha + \epsilon/\sqrt{n}} < \alpha\right]. \end{aligned} \quad (3.9)$$

Soit $p_n = E(\mathbb{1}_{X_i < \xi_\alpha + \epsilon/\sqrt{n}}) = P[X_i < \xi_\alpha + \epsilon/\sqrt{n}]$. La suite (Y_{ni}) , où $Y_{ni} = \mathbb{1}_{X_i < \xi_\alpha + \epsilon/\sqrt{n}} - p_n$, forme un tableau triangulaire de variables centrées et iid pour n fixé. On a

$$E(Y_{ni}) = 0, \quad E(Y_{ni}^2) = p_n(1 - p_n).$$

De plus, avec $s_n^2 = np_n(1 - p_n)$ on a pour tout $\epsilon > 0$, en utilisant le fait que $|Y_{ni}| < 1$,

$$\sum_{i=1}^n \frac{1}{s_n^2} E(Y_{ni}^2 \mathbb{1}_{|Y_{ni}| > \epsilon s_n}) \leq \frac{1}{p_n(1 - p_n)} P[|Y_{n1}| > \epsilon s_n] = 0$$

pour n suffisamment grand car $s_n \rightarrow \infty$.

Par suite, d'après un théorème central limite pour tableaux triangulaires (voir Annexe),

$$Z_n := \frac{\sum_{i=1}^n Y_{ni}}{\sqrt{np_n(1 - p_n)}} \xrightarrow{d} \mathcal{N}(0, 1). \quad (3.10)$$

Or, d'après (3.9), en notant que $\alpha < p_n$,

$$P[\sqrt{n}(\xi_{n,\alpha} - \xi_\alpha) > \epsilon] = P\left[Z_n < \frac{\sqrt{n}(\alpha - p_n)}{\sqrt{p_n(1 - p_n)}}\right] = P\left[Z_n \frac{\epsilon \sqrt{p_n(1 - p_n)}}{\sqrt{n}(\alpha - p_n)} > \epsilon\right].$$

De plus $\sqrt{n}(\alpha - p_n) \rightarrow -\epsilon f(\xi_\alpha)$ quand $n \rightarrow \infty$. Donc d'après (3.10),

$$U_n = Z_n \frac{\epsilon \sqrt{p_n(1 - p_n)}}{\sqrt{n}(\alpha - p_n)} \xrightarrow{d} \mathcal{N}(0, \omega_\alpha^2),$$

ce qui prouve le résultat.




Figure 3.1: Variance asymptotique pour le quantile empirique d'une loi $\mathcal{N}(0, 1)$.




Figure 3.2: Variances asymptotiques pour les quantiles empiriques des lois de Pareto de la figure 2.2.

□

Remarquons que la variance asymptotique dépend de α et de la densité en ξ_α . Le terme $\alpha(1 - \alpha)$ est petit pour les α correspondant aux queues de distribution, mais cet effet est contrebalancé par celui du dénominateur, qui rend l'estimation des quantiles moins précis dans les régions à faible densité. La figure 3.1 montre comment la précision asymptotique dépend de α dans le cas de la loi $\mathcal{N}(0, 1)$. L'effet du dénominateur l'emporte sur celui du numérateur, la précision devenant très faible dans les zones à faible densité. La figure 3.2 présente un comportement similaire (mais ici il n'y a des queues de distribution que du côté positif) pour des lois de Pareto.

Une extension de la preuve précédente fournit la loi asymptotique d'un vecteur de quantiles. Soit $\xi_n = (\xi_{n,\alpha_1}, \dots, \xi_{n,\alpha_p})'$ et soit $\xi = (\xi_{\alpha_1}, \dots, \xi_{\alpha_p})'$ des vecteurs de p quantiles empiriques et théoriques.

Proposition 3.1 *Soit $X_1, \dots, X_n$ un échantillon de variables iid de loi absolument*

continue de densité f . Alors, si $\alpha_i \in]0, 1[$ et $f(\xi_{\alpha_i}) > 0$ pour $i = 1, \dots, p$,

$$\sqrt{n}(\xi_n - \xi) \xrightarrow{d} \mathcal{N}(0, \Omega), \quad \Omega = (\omega_{ij}), \quad \omega_{ij} = \frac{\alpha_i \wedge \alpha_j - \alpha_i \alpha_j}{f(\xi_{\alpha_i})f(\xi_{\alpha_j})}.$$

Notons que la matrice de variance asymptotique Ω peut être estimée par

$$\hat{\Omega} = (\hat{\omega}_{ij}), \quad \hat{\omega}_{ij} = \frac{\alpha_i \wedge \alpha_j - \alpha_i \alpha_j}{\hat{f}(\xi_{n, \alpha_i})\hat{f}(\xi_{n, \alpha_j})}$$

où $\hat{f}$ est un estimateur non paramétrique (obtenu par exemple par la méthode du noyau) de la densité f .

Un résultat plus précis concernant le comportement asymptotique des quantiles empiriques est connu sous le nom de représentation de Bahadur. Pour un échantillon de variables iid, de densité f telle que $f(\alpha) > 0$, Bahadur (1966) a montré que: pour $0 < \alpha < 1$,

$$\xi_{n, \alpha} = \xi_\alpha + \frac{\alpha - F_n(\xi_\alpha)}{f(\xi_\alpha)} + R_n \quad (3.11)$$

où R_n est un terme aléatoire de l'ordre de $(\log \log n/n)^{3/4}$ lorsque n tend vers l'infini. La convergence (3.1) permet de retrouver la loi limite du quantile empirique. Depuis, ce résultat a été étendu à des processus plus généraux. L'extension suivante concerne les processus linéaires. Elle précise également le comportement uniforme de $\xi_{n, \alpha} - \xi_\alpha$ au voisinage de α .

Proposition 3.2 (Wu, 2005) *Si $X_t = \sum_{i=0}^{\infty} a_i \epsilon_{t-i}$ où (ϵ_t) est une suite de variables iid de variance finie et de densité f_ϵ et la suite (a_i) vérifie $\sum_{i=0}^{\infty} |a_i| < \infty$, si*

$$\sup_x (f_\epsilon(x) + |f'_\epsilon(x)|) < \infty, \quad f(\xi_\alpha) > 0,$$

alors on a la représentation (3.11) avec $R_n = O_{p.s.} \left(\left(\frac{\log n}{n} \right)^{3/4} \log \log n \right)^2$.

Si de plus, pour $0 < \alpha_0 < \alpha_1 < 1$,

$$\sup_x |f''_\epsilon(x)| < \infty, \quad \inf_{\alpha_0 < \alpha < \alpha_1} f(\xi_\alpha) > 0,$$

alors

$$\sup_{\alpha_0 < \alpha < \alpha_1} \left| \xi_{n, \alpha} - \xi_\alpha - \frac{\alpha - F_n(\xi_\alpha)}{f(\xi_\alpha)} \right| = O_{p.s.} \left(n^{-3/4} \log^{5/4} n \log \log n \right).$$

²La notation $Z_n = O_{p.s.}(r_n)$ signifie que Z_n/r_n est p.s. bornée.

On a également l'extension suivante, qui concerne les processus non linéaires.

Proposition 3.3 (Wu, 2005) *Si $X_t = G(X_{t-1}, \epsilon_t)$ où (ϵ_t) est une suite de variables iid et $L_\epsilon = \sup_{x \neq x'} |G(x, \epsilon) - G(x', \epsilon)|/|x - x'| \leq \infty$ vérifie*

$$E(\log L_\epsilon) < 0, \quad E|L_\epsilon^r + |x_0 - G(x_0, \epsilon)|^r| < \infty$$

pour un $r > 0$ et un x_0 et si, pour $0 < \alpha_0 < \alpha_1 < 1$,

$$\sup_x (f(x) + |f'(x)|) < \infty, \quad \inf_{\alpha_0 < \alpha < \alpha_1} f(\xi_\alpha) > 0,$$

alors

$$\sup_{\alpha_0 < \alpha < \alpha_1} \left| \xi_{n,\alpha} - \xi_\alpha - \frac{\alpha - F_n(\xi_\alpha)}{f(\xi_\alpha)} \right| = O_{p.s.} \left(n^{-3/4} \log^{3/2} n \right). \quad (3.12)$$

Cette propriété peut en particulier s'appliquer au processus ARCH(1) sous des hypothèses appropriées sur les coefficients. Toutefois, la loi limite des quantiles empiriques ne sera pas obtenue explicitement dans ce cas car la densité marginale des observations est inconnue (même lorsque la loi conditionnelle est gaussienne).

La majoration uniforme (3.12) permet, en utilisant (3.3), d'obtenir la convergence faible suivante

$$\sqrt{n}f(\xi_\alpha)(\xi_{n,\alpha} - \xi_\alpha) \Rightarrow B(\alpha), \quad \alpha \in]\alpha_0, \alpha_1[\quad (3.13)$$

où $\{B(t), t \in [0, 1]\}$ est un pont Brownien.

3.3 Méthodes d'estimation des mesures de risque

Les propriétés statistiques "non standard" des séries financières (présence et regroupement de volatilité, lois marginales leptokurtiques, asymétries) rendent l'estimation de la VaR, et plus généralement des mesures de risque, problématique. Il faut par exemple distinguer VaR conditionnelle et non conditionnelle. Les méthodes d'estimation de quantiles développées dans le cadre iid gaussien sont ici inadaptées.

3.3.1 Estimation non paramétrique

Les résultats de la partie précédente s'appliquent à l'estimation de la VaR non conditionnelle, définie comme le quantile de niveau $1 - \alpha$ de la distribution de perte. La méthode dite de "simulation historique" consiste simplement à estimer la VaR par le quantile empirique de la distribution inconditionnelle de $L_{t,t+h}$ (elle

ne comporte donc pas de simulations au sens statistique du terme). En notant F_n cette distribution, supposée indépendante de t et de h , on a donc l'estimateur

$$\hat{\text{VaR}}_{n,h}(\alpha) = F_n^{\leftarrow}(1 - \alpha).$$

Au lieu de considérer tout l'échantillon, on peut se limiter à une fenêtre mobile limitée aux n_0 dernières observations. Par exemple, si $n_0 = 1000$ la VaR estimée pour un niveau de confiance $\alpha = 5\%$ est simplement le 50ième plus grande observation.

Cette méthode fondée sur les quantiles empiriques a l'avantage de la simplicité et de ne faire aucune hypothèse sur les distributions des variables de perte. Elle présente cependant des inconvénients importants: (i) la VaR estimée est une VaR non conditionnelle; (ii) la loi asymptotique utilisée pour évaluer la précision de l'estimateur dépend, elle, d'hypothèses précises (par exemple l'indépendance et l'équidistribution); (iii) les exemples illustrant le théorème 3.1 montrent que les quantiles correspondant aux queues de distribution sont estimés avec une précision asymptotique très faible; or ce sont précisément ces quantiles auxquels on s'intéresse; (iv) la méthode ne permet pas de prendre en compte l'influence de variables explicatives (présente ou passées) dans la mesure du risque.

Des estimateurs non paramétriques peuvent également être construits pour l'expected shortfall (voir Scaillet, 2005). Plus généralement, un estimateur non paramétrique de la mesure de distorsion de risque

$$r(F; G) = \int_0^1 F^{-1}(1 - u) dG(u),$$

où G est une fonction de répartition sur $[0, 1]$ et F est la distribution de perte, supposée strictement croissante et continue, est

$$r(F_n; G) = \int_0^1 F_n^{\leftarrow}(1 - u) dG(u).$$

La fonction quantile empirique étant en escalier, il est facile d'exprimer cette intégrale en fonction des observations:

$$r(F_n; G) = \sum_{i=0}^{n-1} \left\{ G\left(\frac{i+1}{n}\right) - G\left(\frac{i}{n}\right) \right\} X_{n,n-i}.$$

Cet estimateur, appelé L -estimateur dans la littérature statistique, apparaît comme une combinaison linéaire des observations ordonnées avec une pondération dépendant des variations de G . On voit en particulier que si G est concave, les grandes observations seront surpondérées.

Dans le cas d'observations iid, la loi asymptotique de l'estimateur $r(F_n; G)$ peut être obtenue à partir de la convergence faible (3.37) du processus quantile $\xi_{n,\alpha}$ vers le processus quantile théorique. On a

$$\sqrt{n}\{r(F_n; G) - r(F; G)\} \Rightarrow \int_0^1 \frac{B(1-u)}{f(\xi_{1-u})} dG(u), \quad (3.14)$$

où $\{B(t), t \in [0, 1]\}$ est un pont Brownien. La loi limite est centrée, de variance donnée par

$$\text{Var}_{as}[\sqrt{n}\{r(F_n; G) - r(F; G)\}] = \int_0^1 \int_0^1 \frac{u_1 \wedge u_2 - u_1 u_2}{f(\xi_{1-u_1})f(\xi_{1-u_2})} dG(u_1) dG(u_2).$$

Si G admet une densité g on obtient, en notant que $1/f(\xi_\alpha)$ est la dérivée de $F^{-1}(\alpha)$, puis par le changement de variable $u = F(x) = 1 - S(x)$,

$$\begin{aligned} & \text{Var}_{as}[\sqrt{n}\{r(F_n; G) - r(F; G)\}] \\ &= \int_0^1 \int_0^1 (u_1 \wedge u_2 - u_1 u_2) g(u_1) g(u_2) dF^{-1}(u_1) dF^{-1}(u_2) \\ &= \int_0^1 \int_0^1 \{F(x_1) \wedge F(x_2) - F(x_1)F(x_2)\} g\{S(x_1)\} g\{S(x_2)\} dx_1 dx_2. \end{aligned}$$

Exemple 3.1 Dans le cas de l'expected shortfall, qui correspond à $g(u) = \mathbb{1}_{[0,\alpha]}(u)$, l'estimateur s'écrit

$$ES_n(\alpha) = \frac{1}{n\alpha} \sum_{i=0}^{[n\alpha]-1} X_{n-i,n} + \left(1 - \frac{[n\alpha]}{n\alpha}\right) X_{n-[n\alpha],n}.$$

Ainsi si $n\alpha = k$, l'estimateur n'est autre que la moyenne des k plus grandes observations.

On montre (voir Gouriéroux et Liu, 2007) que la variance asymptotique de l'estimateur dépend de la variance de la perte lorsqu'elle dépasse la VaR et de l'écart entre l'ES et la VaR:

$$\text{Var}_{as}[\sqrt{n}\{ES_n(\alpha) - ES(\alpha)\}] = \frac{(V[L \mid L > \text{VaR}(\alpha)] + (1 - \alpha)\{ES(\alpha) - \text{VaR}(\alpha)\}^2)}{\alpha}$$

3.3.2 Modèles dynamiques des moments conditionnels

Une approche paramétrique de la VaR consiste à spécifier les moments conditionnels de la variable de perte. Un modèle classique, en notant L_t la variable de perte entre les dates $t - 1$ et t , est

$$L_t = m_t(\theta) + \sigma_t(\theta)\epsilon_t$$

où $m_t(\theta)$ et $\sigma_t^2(\theta)$ sont, respectivement, l'espérance et la variance conditionnelles au passé de L_t et θ est un vecteur de paramètres. Si l'on suppose la suite (ϵ_t) iid, de loi F , la VaR (à horizon 1) prend la forme

$$\text{VaR}_{t,1}(\alpha) = m_t(\theta) + \sigma_t(\theta)F^{\leftarrow}(1 - \alpha). \quad (3.15)$$

Si la loi des termes d'erreur est supposée connue, un estimateur $\hat{\theta}$ de θ permet d'obtenir un estimateur paramétrique de la VaR défini par

$$\hat{\text{VaR}}_{t,1}^{(1)}(\alpha) = m_t(\hat{\theta}) + \sigma_t(\hat{\theta})F^{\leftarrow}(1 - \alpha). \quad (3.16)$$

Dans le cas, plus réaliste, où la loi des termes d'erreur n'est pas connue un estimateur semi-paramétrique de la VaR peut être défini par

$$\hat{\text{VaR}}_{t,1}^{(2)}(\alpha) = m_t(\hat{\theta}) + \sigma_t(\hat{\theta})\hat{F}^{\leftarrow}(1 - \alpha) \quad (3.17)$$

où $\hat{F}^{\leftarrow}(1 - \alpha)$ est un quantile empirique obtenu à partir des résidus $\hat{\epsilon}_t = (L_t - m_t(\hat{\theta}))/\sigma_t(\hat{\theta})$. Une solution intermédiaire consiste à supposer que la loi de ϵ_t appartient à une famille paramétrée, $\{F_\beta\}$. À partir d'un estimateur $\hat{\beta}$ du paramètre de cette loi on définit

$$\hat{\text{VaR}}_{t,1}^{(3)}(\alpha) = m_t(\hat{\theta}) + \sigma_t(\hat{\theta})F_{\hat{\beta}}^{\leftarrow}(1 - \alpha). \quad (3.18)$$

Un autre estimateur est obtenu en utilisant l'estimateur du quasi-maximum de vraisemblance gaussien

$$\hat{\text{VaR}}_{QMV}(\alpha) = m_t(\hat{\theta}_{QMV}) + \sigma_t(\hat{\theta}_{QMV})\Phi^{-1}(1 - \alpha). \quad (3.19)$$

Les spécifications les plus utilisées pour le calcul des moments conditionnels sont celles des modèles ARMA et GARCH.

Remarquons que ces diverses méthodes ont l'avantage de fournir toutes des estimateurs de la VaR fonctions décroissantes de α . Cette propriété ne sera pas assurée pour d'autres estimateurs vus par la suite.

Modèle Riskmetrics

La méthode RiskMetricsTM a été développée par J.P. Morgan pour calculer la VaR. Elle repose sur le modèle suivant, écrit pour une série de rendements en logarithme, $r_t = \log(p_t/p_{t-1})$,

$$\begin{cases} r_{t+1} &= \sigma_{t+1}\eta_{t+1}, & (\eta_t) \text{ iid } \mathcal{N}(0, 1) \\ \sigma_{t+1}^2 &= \lambda\sigma_t^2 + (1 - \lambda)r_t^2 \end{cases} \quad (3.20)$$

où $\lambda \in]0, 1[$ est un paramètre de lissage (arbitrairement fixé à 0.94 pour les séries journalières). Ainsi σ_{t+1}^2 est simplement la prévision de r_{t+1}^2 obtenue par lissage exponentiel simple.

Ce modèle peut également s'interpréter comme un IGARCH(1,1)³ sans terme constant. Il est cependant important de remarquer que (A.1) ne constitue pas véritablement un modèle: pour toute valeur r_0 initiale, r_t tend presque sûrement vers 0 lorsque t tend vers l'infini. Il est donc clair que (A.1) ne peut être le DGP (processus générateur de données) d'aucune série financière usuelle. Ce modèle peut néanmoins être utilisé comme moyen de calcul de la VaR.

La VaR à horizon 1 au niveau α de la variable de perte $L_{t,t+1} = -r_{t+1}$ est, puisque la loi conditionnelle de $L_{t,t+1}$ est la loi $\mathcal{N}(0, \sigma_{t+1}^2)$,

$$\text{VaR}_{t+1,1}(\alpha) = \sigma_{t+1} \Phi^{-1}(1 - \alpha). \quad (3.21)$$

Aux horizons supérieurs, le calcul de la VaR est problématique. La formule suivante est couramment utilisée

$$\text{VaR}_{t+1,h}(\alpha) = \sigma_{t+1} \sqrt{h} \Phi^{-1}(1 - \alpha), \quad (3.22)$$

mais nous allons voir qu'elle est fautive. En effet, la perte à horizon h pour les logarithmes de prix est

$$L_{t,t+h} = -(\log p_{t+h} - \log p_t) = -\sum_{i=1}^h r_{t+i}$$

et sa variance conditionnelle est

$$V_t(L_{t,t+h}) = \sum_{i=1}^h V_t(r_{t+i}) = \sum_{i=1}^h E_t(r_{t+i}^2) = \sum_{i=1}^h E_t(\sigma_{t+i}^2).$$

Pour la première égalité nous avons utilisé la relation $E_t(r_{t+i}r_{t+j}) = 0$ pour $i \neq j$. Or on peut écrire, en posant $a(\eta_t) = \lambda + (1 - \lambda)\eta_t^2$, pour $i \geq 1$

$$\sigma_{t+i}^2 = a(\eta_{t+i-1})\sigma_{t+i-1}^2 = a(\eta_{t+i-1}) \dots a(\eta_{t+1})\sigma_{t+1}^2, \quad (3.23)$$

donc, puisque $E\{a(\eta_t)\} = 1$,

$$E_t\sigma_{t+i}^2 = E\{a(\eta_{t+i})\} \dots E\{a(\eta_{t+2})\}\sigma_{t+1}^2 = \sigma_{t+1}^2.$$

Finalement,

$$V_t(L_{t,t+h}) = h\sigma_{t+1}^2,$$

³GARCH intégré, car la somme des coefficients de σ_t^2 et r_t^2 vaut 1.

ce qui explique la forme utilisée pour $\text{VaR}_{t+1,h}(\alpha)$. Cependant la formule (3.22) est incorrecte car la loi conditionnelle de $L_{t,t+h}$ n'est pas gaussienne⁴. La formule correcte est

$$\text{VaR}_{t+1,h}(\alpha) = \sigma_{t+1} \sqrt{h} F_h^{-1}(1 - \alpha), \quad (3.24)$$

où F_h est la fonction de répartition de $L_{t,t+h}/\{\sigma_{t+1}\sqrt{h}\}$. Cette loi peut être estimée non paramétriquement à partir des $-\sum_{i=1}^h r_{t+i}/\{\hat{\sigma}_{t+1}\sqrt{h}\}$ où $\hat{\sigma}_{t+1}^2 = \hat{\lambda}\sigma_t^2 + (1-\hat{\lambda})r_t^2$ et $\hat{\lambda}$ désigne un estimateur de λ .

Des calculs analogues peuvent évidemment être effectués pour un modèle GARCH(1,1) plus général, mais on perd la forme en $\sqrt{h}$ donnée par la formule (3.24). En effet, (3.23) n'est alors plus valide, les σ_{t+i}^2 étant de la forme $\alpha(\eta_{t+i}, \dots, \eta_{t+2}) + \beta(\eta_{t+i}, \dots, \eta_{t+2})\sigma_{t+1}^2$.

3.3.3 Régression quantile

La régression quantile (voir le livre de Koenker, 2005) peut s'interpréter à partir de la régression linéaire classique. Rappelons que celle-ci spécifie l'espérance d'un vecteur $Y = (Y_1, \dots, Y_n)'$, conditionnellement à une matrice $n \times k$ de variables exogènes X sous la forme

$$E(Y_i | X) = X_i' \beta, \quad i = 1, \dots, n \quad (3.25)$$

où les X_i' sont les lignes de X et $\beta \in \mathbb{R}^k$ est le paramètre inconnu. De manière équivalente, on peut considérer le modèle

$$Y_i = X_i' \beta + \epsilon_i, \quad E(\epsilon_i | X) = 0, \quad i = 1, \dots, n. \quad (3.26)$$

D'autres hypothèses sont évidemment nécessaires sur les termes d'erreur ϵ_i et sur la matrice X pour estimer β .

Soit $\alpha \in]0, 1[$ et soit $F_W^{\leftarrow}(\alpha | X)$ la fonction quantile associée à la loi d'une variable W sachant X . La régression quantile remplace les équations précédentes par

$$F_{Y_i}^{\leftarrow}(\alpha | X) = X_i' \beta(\alpha), \quad i = 1, \dots, n \quad (3.27)$$

et, de manière équivalente étant donnée l'additivité par rapport aux constantes de la fonction quantile

$$Y_i = X_i' \beta(\alpha) + \epsilon_i, \quad F_{\epsilon_i}^{\leftarrow}(\alpha | X) = 0, \quad i = 1, \dots, n \quad (3.28)$$

⁴Par exemple pour $h = 2$ on a $L_{t,t+2} = -\sigma_{t+1}\{\eta_{t+1} + \sqrt{a(\eta_{t+1})}\eta_{t+2}\}$ et le Kurtosis de la loi conditionnelle vaut

$$3 \left(\frac{(1-\lambda)(3-\lambda)}{2} + 1 \right) \neq 3.$$

où $\beta(\alpha) \in \mathbb{R}^k$ est un paramètre. Lorsque X est une colonne de 1, $\beta(\alpha) \in \mathbb{R}$ n'est autre que le quantile d'ordre α des Y_i .

Remarque 3.1 L'analogie entre les modèles (3.26) et (3.27) est trompeuse car cette dernière équation est en réalité une égalité fonctionnelle (en α). Il est rare que l'on cherche à modéliser le quantile correspondant à un α particulier. Plus généralement, on s'intéresse aux valeurs de α appartenant à un intervalle inclus dans $]0, 1[$. Dans cette optique, des contraintes sont nécessaires pour assurer que $X'_i\beta(\alpha)$ soit une fonction quantile. Le modèle de base (*location-scale shift model*) s'écrit

$$F_{Y_i}^{\leftarrow}(\alpha | X) = X'_i\theta + X'_i\gamma F_0^{\leftarrow}(\alpha), \quad i = 1, \dots, n \quad (3.29)$$

où $\theta \in \mathbb{R}^k$ et $\gamma \in \mathbb{R}^k$ sont des paramètres et $F_0^{\leftarrow}(\cdot)$ une fonction quantile donnée. Afin d'assurer la croissance de la fonction $F_{Y_i}^{\leftarrow}(\cdot | X)$ il faut contraindre les variables exogènes et l'espace des paramètres pour avoir

$$X'_i\gamma \geq 0, \quad i = 1, \dots, n.$$

Remarquons que la spécification (3.29) équivaut au modèle

$$Y_i = X'_i\theta + (X'_i\gamma)\epsilon_i, \quad i = 1, \dots, n \quad (3.30)$$

où les "termes d'erreur"⁵ ϵ_i sont de distribution F_0 .

Remarque 3.2 Le modèle (3.27), si on le considère valable pour tout $\alpha \in]0, 1[$, caractérise entièrement la loi des Y_i (conditionnellement à X). Une façon très simple de *simuler* les Y_i consiste à simuler des variables U_i de loi $\mathcal{U}[0, 1]$ et à prendre

$$Y_i = X'_i\beta(U_i), \quad i = 1, \dots, n. \quad (3.31)$$

On sait en effet qu'une variable de loi F est obtenue en posant $Y = F^{\leftarrow}(U)$ où $U \sim \mathcal{U}[0, 1]$. Par exemple des simulations du modèle (3.29) sont obtenues à partir de

$$Y_i = X'_i\theta + X'_i\gamma F_0^{\leftarrow}(U_i), \quad i = 1, \dots, n. \quad (3.32)$$

Si l'on raisonne à α fixé, un estimateur de $\beta(\alpha)$ dans le modèle (3.27) découle naturellement de la formule (3.5) pour les quantiles empiriques. On pose

$$\hat{\beta}(\alpha) = \arg \min_{\beta \in \mathbb{R}^k} \frac{1}{n} \sum_{i=1}^n \rho_{\alpha}(Y_i - X'_i\beta) := \arg \min_{\beta \in \mathbb{R}^k} f_{n,\alpha}(\beta). \quad (3.33)$$

⁵l'interprétation usuelle ne fonctionne pas toujours car ces termes ne sont pas nécessairement centrés.

La loi limite de l'estimateur peut être obtenue sous diverses hypothèses concernant les variables Y_i et X_i . Pour simplifier nous supposons que les variables Y_i sont indépendantes, de loi F_{Y_i} conditionnellement à X . On note $\xi_i(\alpha) = F_{Y_i}^{\leftarrow}(\alpha)$. Nous admettrons le résultat suivant.

Proposition 3.4 *On suppose que les F_i sont absolument continues, de densité f_i strictement positives en $\xi_i(\alpha)$. Supposons de plus qu'il existe des matrices Ω_0 et $\Omega_1(\alpha)$ définies positives telles que presque sûrement*

1. $\frac{1}{n} \sum_{i=1}^n X_i X_i' \rightarrow \Omega_0$,
2. $\frac{1}{n} \sum_{i=1}^n f_i(\xi_i(\alpha)) X_i X_i' \rightarrow \Omega_1(\alpha)$,
3. $\max_{i=1, \dots, n} \|X_i\| / \sqrt{n} \rightarrow 0$.

Alors

$$\sqrt{n}\{\hat{\beta}(\alpha) - \beta(\alpha)\} \xrightarrow{d} \mathcal{N}(0, \alpha(1-\alpha)\Omega_1^{-1}(\alpha)\Omega_0\Omega_1^{-1}(\alpha))$$

Remarque 3.3 Les résultats précédents sont valables pour un α donné mais si on considère plusieurs niveaux α , rien n'assure de la cohérence (monotonie) des estimateurs obtenus. Autrement dit, dans le plan, les droites de régression quantiles estimées pour des α différents peuvent se croiser. Il est cependant possible de montrer que au centre du nuage de points, la monotonie est respectée. Plus précisément, en notant $\bar{X}$ la moyenne empirique des X_i , on a

$$\alpha_1 \geq \alpha_2 \quad \Rightarrow \quad \bar{X}'\hat{\beta}(\alpha_1) \geq \bar{X}'\hat{\beta}(\alpha_2)$$

(voir Koenker, 2005, Theorem 2.5).

Reprenant les notations utilisées pour les variables de perte, un estimateur de la VaR, conditionnelle à l'information représentée par le vecteur x_t , est donc

$$\text{VaR}_t(\alpha) = x_t' \hat{\beta}(\alpha).$$

Il est ici naturel d'introduire dans le vecteur x_t des variables retardées. Les résultats asymptotiques sont alors à reconsidérer. Cette approche peut évidemment être étendue au cadre non linéaire en spécifiant la VaR comme une fonction de la forme $g(x_t, \beta, \alpha)$. L'estimateur obtenu est convergent (vers β_0 tel que $\text{VaR}_t(\alpha) = g(x_t, \beta_0, \alpha)$) et asymptotiquement normal sous diverses conditions de dépendance (voir Portnoy (1991)) incluant en particulier le cas ARCH (voir Koenker et Zhao (1996)). Une généralisation introduite par Engle et Manganelli (2004), que nous verrons plus loin, spécifie un modèle dynamique pour la VaR. Remarquons qu'un inconvénient de cette méthode, menée séparément pour diverses valeurs de α , est que rien n'assure la monotonie de $\text{VaR}(\alpha)$ comme fonction de α .

3.3.4 Modèles dynamiques de la VaR

Il existe plusieurs façons de modéliser les lois conditionnelles. La plus usuelle, en économétrie, consiste à modéliser les *densités* conditionnelles. C'est par exemple ce qu'on fait lorsqu'on spécifie un modèle ARCH avec bruit iid gaussien. Un autre type de modélisation consiste à spécifier les *transformées de Laplace* conditionnelles. Cette approche est couramment utilisée en finance (voir par exemple les modèles affines, les modèles CAR (Compound Autoregressive)). Une troisième méthode, qui semble plus naturelle pour l'évaluation du risque, consiste à spécifier les *quantiles* conditionnels.

Comme nous l'avons remarqué, une des difficultés est de spécifier un modèle pour les quantiles conditionnels prenant en compte la monotonie de la fonction $\alpha \mapsto \text{VaR}_t(\alpha)$.

Modèles QAR (Quantile AutoRegressive)

La formule (3.31) fournit une méthode de simulation du modèle de régression quantile (3.28). Elle s'interprète également comme la spécification à coefficients aléatoires d'un modèle à variables exogènes. Une généralisation naturelle au cadre autorégressif, introduite par Koenker et Xiao (2006), s'écrit

$$Y_t = a_0(U_t) + a_1(U_t)Y_{t-1} + \dots + a_p(U_t)Y_{t-p}, \quad (3.34)$$

où (U_t) est une suite iid de variables de loi $\mathcal{U}(0, 1]$, les $a_i(\cdot)$ sont des fonctions $[0, 1] \mapsto \mathbb{R}$ à estimer. Ce modèle peut être appelé autorégression quantile d'ordre p ou QAR(p). A condition que le membre de droite de l'égalité (3.34) soit une fonction croissante de U_t , la fonction quantile conditionnelle de y_t s'écrit⁶

$$F_{Y_t}^{\leftarrow}(\alpha \mid Y_{t-1}, \dots, Y_{t-p}) = a_0(\alpha) + a_1(\alpha)Y_{t-1} + \dots + a_p(\alpha)Y_{t-p}, \quad \forall \alpha \in]0, 1[. \quad (3.35)$$

Cette restriction est importante car la monotonie doit avoir lieu quelles que soient les valeurs prises par les variables Y_{t-i} . Elle est cependant facile à vérifier lorsque les Y_i sont des variables positives et les $a_i(\cdot)$ des fonctions quantiles.

Des contraintes sont également nécessaires pour assurer la stationnarité des solutions (Y_t) du modèle (3.34). Dans le cas $p = 1$ on voit en déroulant le modèle que

$$Y_t = a_0(U_t) + \sum_{i=0}^{\infty} a_1(U_t) \dots a_1(U_{t-i}) a_0(U_{t-i-1})$$

⁶car pour toute fonction croissante g et toute variable $U \sim \mathcal{U}[0, 1]$ on a $F_{g(U)}^{\leftarrow}(\alpha) = g(F_U^{\leftarrow}(\alpha)) = g(\alpha)$.

à condition que la somme infinie converge. Par la règle de Cauchy, on obtient une condition de convergence absolue de cette somme, et donc de stricte stationnarité de Y_t :

$$E \log |a_1(U_t)| < 0, \quad E \log |a_0(U_t)| < +\infty.$$

De même, une condition de stationnarité au second-ordre (et au sens strict) est

$$Ea_1^2(U_t) < 1, \quad Ea_0^2(U_t) < +\infty.$$

Notons que ces conditions n'imposent pas que la fonction $a_1(\cdot)$ soit majorée par 1. Des conditions peuvent être établies dans le cas général à partir d'une représentation vectorielle du modèle (3.34).

Pour α fixé, on obtient un estimateur du vecteur des paramètres $a(\alpha) = (a_0(\alpha), \dots, a_p(\alpha))'$ comme solution de

$$\hat{a}(\alpha) = \arg \min_{a \in \mathbb{R}^{p+1}} \frac{1}{n} \sum_{i=1}^n \rho_\alpha(Y_t - a_0 - a_1 Y_{t-1} - \dots - a_p Y_{t-p}) \quad (3.36)$$

où $\rho_\alpha(u) = \alpha u^+ + (\alpha - 1)(-u)^+ = u(\alpha - \mathbb{1}_{u < 0})$. Sous des conditions de régularité sur les fonctions a_i (impliquant la stationnarité au second ordre), Koenker et Xiao (2006, Theorem 2) montrent la convergence faible

$$\Sigma^{-1/2}(\alpha) \sqrt{n} \{\hat{a}(\alpha) - a(\alpha)\} \Rightarrow B(\alpha), \quad (3.37)$$

où $\{B_{p+1}(t), t \in [0, 1]\}$ est un pont Brownien de dimension $p + 1$ et $\Sigma(\alpha)$ est une matrice non aléatoire.

La remarque effectuée pour la régression quantile est toujours valable dans le cadre autorégressif: l'inconvénient principal de cette approche est qu'elle ne garantit pas la monotonie de la fonction quantile estimée.

Modèles CAViaR (Conditional Autoregressive VaR)

Ces modèles, introduits par Engle et Manganelli (2004), se distinguent des précédents par l'introduction de quantiles passés dans la spécification du quantile de la date courante. Un modèle général de cette forme s'écrit donc, $\forall \alpha \in]0, 1[$

$$\begin{aligned} q_t(\alpha) &:= F_{Y_t}^{\leftarrow}(\alpha \mid Y_{t-1}, Y_{t-2}, \dots) \\ &= a_0(\alpha) + \sum_{i=1}^p a_i(\alpha) g(Y_{t-i}) + \sum_{j=1}^r b_j q_{t-j}(\alpha) \end{aligned} \quad (3.38)$$

où $g : \mathbb{R} \mapsto \mathbb{R}^+$. Des exemples de fonctions g sont $g(y) = y^2$, $g(y) = |y|$ mais également des fonctions permettant de prendre en compte des effets d'asymétrie dans

le quantile conditionnel, comme par exemple $g(y) = \beta_1 y^+ + \beta_2 (-y)^+$ (la fonction g pouvant donc comporter des paramètres à estimer). Dans cette spécification, les observations passées positives et négatives de même module auront un impact différent sur le quantile conditionnel (par analogie avec les modèles GARCH asymétriques pour la variance conditionnelle).

Si le polynôme $b(z) = 1 - \sum_{j=1}^r b_j z^j$ a toutes ses racines à l'extérieur du disque unité, il est inversible. En notant $a_\alpha(z) = \sum_{i=1}^p a_i(\alpha) z^i$ et L l'opérateur retard on a

$$\begin{aligned} q_t(\alpha) &= \beta^{-1}(1) a_0(\alpha) + b^{-1}(L) \sum_{i=1}^p a_i(\alpha) g(Y_{t-i}) \\ &:= a_0^*(\alpha) + \sum_{i=1}^{\infty} a_i^*(\alpha) g(Y_{t-i}). \end{aligned} \quad (3.39)$$

La positivité de g , celle des coefficients b_j et la croissance des fonctions a_i assurent donc la croissance de $q_t(\cdot)$ (car les coefficients du polynôme $b^{-1}(z)$ sont alors positifs).

L'existence de processus (Y_t) admettant les quantiles conditionnels définis par (3.38) est problématique. Sous les conditions précédentes, il suffit de chercher des processus (Y_t) solution de

$$Y_t = a_0^*(U_t) + \sum_{i=1}^{\infty} a_i^*(U_t) g(Y_{t-i})$$

où (U_t) est une suite iid de variables de loi $\mathcal{U}(0, 1]$.

Modèles DAQ (Dynamic Additive Quantile)

Ces modèles, introduits par Gouriéroux et Jasiak (2007), s'écrivent, avec les notations précédentes,

$$\begin{aligned} q_t(\alpha) &:= F_{Y_t}^{\leftarrow}(\alpha \mid Y_{t-1}, Y_{t-2}, \dots) \\ &= g_0(Y_{t-1}, Y_{t-2}, \dots) + \sum_{i=1}^p a_i(\alpha) g_i(Y_{t-1}, Y_{t-2}, \dots) \end{aligned} \quad (3.40)$$

où les a_i sont des fonctions quantiles, les g_i sont des fonctions positives ou nulles (avec par exemple $g_0 > 0$) des variables passées. Toutes ces fonctions sont paramétrées.

La représentation (3.39) montre que les modèles CAViAR sont des cas particuliers de modèle DAQ. D'autres spécifications des fonctions a_i et g_i permettent de faire

apparaître des effets ARCH. Par exemple on peut prendre, en utilisant les fonctions quantiles des lois normale et de Cauchy standard,

$$\begin{aligned} q_t(\alpha) &= m_0 + m_1|Y_{t-1} - \mu| + \{\sigma_{0,0} + \sigma_{0,1}Y_{t-1}^2\}^{1/2}\Phi^{-1}(\alpha) \\ &\quad + \{\sigma_{1,0} + \sigma_{1,1}Y_{t-1}^2\}^{1/2}\tan\{\pi(\alpha - 1/2)\}. \end{aligned} \quad (3.41)$$

Le membre de droite de l'équation (3.40) étant une fonction croissante de α , il est possible de simuler le processus (Y_t) à partir du modèle à coefficients aléatoires

$$Y_t = g_0(Y_{t-1}, Y_{t-2}, \dots) + \sum_{i=1}^p a_i(U_t)g_i(Y_{t-1}, Y_{t-2}, \dots)$$

où (U_t) iid $\sim \mathcal{U}[0, 1]$. Par exemple, dans le cas du modèle (3.41) avec $\sigma_{1,0} = \sigma_{1,1} = 0$, on obtient

$$Y_t = m_0 + m_1|Y_{t-1} - \mu| + \{\sigma_{0,0} + \sigma_{0,1}Y_{t-1}^2\}^{1/2}\epsilon_t$$

où (ϵ_t) iid $\sim \mathcal{N}(0, 1)$.

Le modèle DAQ peut aussi être utilisé pour spécifier d'autres mesures de risque dynamiques. Par exemple, du modèle (3.41) on tire la DRM dynamique

$$\begin{aligned} r(F_t; G) &= m_0 + m_1|Y_{t-1} - \mu| + \{\sigma_{0,0} + \sigma_{0,1}Y_{t-1}^2\}^{1/2} \int_0^1 \Phi^{-1}(u)dG(u) \\ &\quad + \{\sigma_{1,0} + \sigma_{1,1}Y_{t-1}^2\}^{1/2} \int_0^1 \tan\{\pi(u - 1/2)\}dG(u). \end{aligned} \quad (3.42)$$

Comme pour les modèles QAR, l'estimation des modèles DAQ peut être menée par la méthode de régression quantile. Des méthodes plus efficaces, fondées sur le critère d'information de Kullback-Leibler, peuvent également être utilisées (voir Gouriéroux et Jasiak, 2007).

Appendix A

Examens

ENSAE - 3ème année, Master MASEF

Juin 2008

MESURES DE RISQUE

Examen

Durée: 2 heures. Sans document.

Les exercices sont indépendants.

Exercice 1: Soit L est une variable de perte, de fonction de répartition supposée continue et strictement croissante et telle que $E|L| < \infty$. On définit la valeur à risque (non conditionnelle) de niveau α par $\text{VaR}(\alpha) = \inf\{x \in \mathbb{R} \mid P[L \leq x] \geq 1 - \alpha\}$ et l'expected shortfall de niveau $\alpha \in]0, 1[$ par $\text{ES}(\alpha) = E[L \mid L > \text{VaR}(\alpha)]$.

1. La fonction $\alpha \mapsto \text{VaR}(\alpha)$ est-elle continue? est-elle strictement monotone?
2. Montrer que $\text{ES}(\alpha) = \frac{1}{\alpha} E[L \mathbf{1}_{L > \text{VaR}(\alpha)}]$.
3. Montrer que $\alpha \mapsto \text{ES}(\alpha)$ est continue.
4. Montrer que pour tout $\epsilon > 0$ tel que $\alpha + \epsilon < 1$ on a

$$\alpha \mathbf{1}_{L > \text{VaR}(\alpha + \epsilon)} - (\alpha + \epsilon) \mathbf{1}_{L > \text{VaR}(\alpha)} \begin{cases} \leq 0, & \text{si } L > \text{VaR}(\alpha) \\ \geq 0, & \text{si } L \leq \text{VaR}(\alpha) \end{cases}$$

En déduire

$$E[L \{\alpha \mathbf{1}_{L > \text{VaR}(\alpha + \epsilon)} - (\alpha + \epsilon) \mathbf{1}_{L > \text{VaR}(\alpha)}\}] \leq E[\text{VaR}(\alpha) \{\alpha \mathbf{1}_{L > \text{VaR}(\alpha + \epsilon)} - (\alpha + \epsilon) \mathbf{1}_{L > \text{VaR}(\alpha)}\}].$$

En déduire que

$$\text{ES}(\alpha + \epsilon) \leq \text{ES}(\alpha).$$

5. On dit qu'une loi F vérifie la propriété (P) si pour L_1 et L_2 de loi F on a, pour tout $\alpha \in]0, 1[$,

$$\text{VaR}_{L_1 + L_2}(\alpha) \leq 2\text{VaR}_{L_1}(\alpha),$$

où $\text{VaR}_L(\alpha)$ désigne la VaR au niveau α d'une variable de perte L .

- (a) Quelle est l'interprétation financière de cette propriété?
- (b) Est-elle vérifiée pour la loi exponentielle de fonction de répartition $F(x) = (1 - e^{-x}) \mathbf{1}_{x > 0}$?

Exercice 2:

Notations et rappels: Soit $X_1, \dots, X_n$ un échantillon de variables iid de loi absolument continue de densité f et de fonction de répartition F . Si $\alpha \in]0, 1[$ on note $\xi_\alpha = F^\leftarrow(\alpha)$ le quantile d'ordre α de la loi des X_i . Pour des observations $X_1, \dots, X_n$, on note F_n la fonction de répartition empirique et $\xi_{n,\alpha} = F_n^\leftarrow(\alpha)$ le quantile empirique d'ordre α .

Si $f(\xi_\alpha) > 0$, on a la convergence en loi

$$\sqrt{n}(\xi_{n,\alpha} - \xi_\alpha) \xrightarrow{d} \mathcal{N}(0, \omega_\alpha^2), \quad \omega_\alpha^2 = \frac{\alpha(1-\alpha)}{f^2(\xi_\alpha)}. \quad (\text{A.1})$$

On appelle loi de Pareto de paramètre (a, b) , avec $a > 1$ et $b > 0$, la loi de fonction de répartition $F(x) = (1 - (\frac{x}{b})^{-a}) \mathbb{1}_{x>b}$ où $\mathbb{1}_{x>b} = 1$ si $x > b$, 0 sinon. La fonction de répartition de la loi $\mathcal{N}(0, 1)$ est notée Φ . On pose $u^+ = \max(u, 0)$.

On note L_t une variable de perte entre les dates $t-1$ et t . On dispose d'observations $L_1, \dots, L_n$ de cette variable. Soit $\alpha \in]0, 1[$.

1. Donner un estimateur $\hat{\text{VaR}}_n(\alpha)$ de la valeur à risque au niveau α de la distribution (non conditionnelle) de perte.
2. On suppose dans cette question que les variables L_i sont iid de loi de Pareto de paramètre $(2, 1)$. Quelle est la loi asymptotique de l'estimateur $\hat{\text{VaR}}_n(\alpha)$? Comment se comporte la variance asymptotique lorsque α tend vers zéro? est-ce étonnant?
3. On suppose maintenant que l'on dispose d'observations $X_1, \dots, X_n$ d'une variable explicative réelle. On a le modèle

$$L_i = X_i \beta(\alpha) + \epsilon_i, \quad F_{\epsilon_i}^\leftarrow(\alpha \mid X_i) = 0, \quad i = 1, \dots, n.$$

La dernière égalité signifie que le quantile d'ordre α de ϵ_i sachant X_i est nul. On note

$$\hat{\beta}(\alpha) = \arg \min_{\beta \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n \rho_\alpha(L_i - X_i \beta), \quad \rho_\alpha(u) = \alpha u^+ + (1 - \alpha)(-u)^+.$$

- (a) A partir des dérivées à gauche et à droite de la fonction ρ_α , écrire les conditions du premier ordre caractérisant $\hat{\beta}(\alpha)$.
- (b) Comment s'interprète $X_i \hat{\beta}(1 - \alpha)$? Dans quel cas retrouve-t-on l'estimateur de la question 1?

- (c) Lorsque α varie quel est le défaut de cette méthode?
- (d) Ayant estimé le modèle, on dispose des résidus $\hat{\epsilon}_i = L_i - X_i\hat{\beta}(1 - \alpha)$.
Proposer une ou plusieurs méthodes pour valider le modèle à partir de ces résidus.

Eléments de corrigé

Exercice 1:

1. La fonction de répartition de L étant strictement croissante, sa fonction quantile est continue. Par suite $\alpha \mapsto \text{VaR}(\alpha)$ est continue. Elle est strictement croissante car la fonction de répartition est continue.
2. Voir cours.
3. La continuité de $ES(\alpha)$ découle de celle de $\text{VaR}(\alpha)$ et de la formule précédente.
4. Si $L > \text{VaR}(\alpha)$ les deux indicatrices valent 1, donc la quantité étudiée vaut $\alpha - (\alpha + \epsilon) = -\epsilon < 0$. Si $L \leq \text{VaR}(\alpha)$, la deuxième indicatrice est nulle donc la quantité est positive ou nulle.

Par suite

$$(L - \text{VaR}(\alpha))\{\alpha \mathbb{1}_{L > \text{VaR}(\alpha + \epsilon)} - (\alpha + \epsilon) \mathbb{1}_{L > \text{VaR}(\alpha)}\} \leq 0.$$

On obtient l'inégalité cherchée en prenant l'espérance.

On remarque ensuite que

$$E[\text{VaR}(\alpha)\{\alpha \mathbb{1}_{L > \text{VaR}(\alpha + \epsilon)} - (\alpha + \epsilon) \mathbb{1}_{L > \text{VaR}(\alpha)}\}] = \text{VaR}(\alpha)\{\alpha(\alpha + \epsilon) - (\alpha + \epsilon)\alpha\} = 0.$$

Par suite

$$E[L\{\alpha \mathbb{1}_{L > \text{VaR}(\alpha + \epsilon)} - (\alpha + \epsilon) \mathbb{1}_{L > \text{VaR}(\alpha)}\}] \leq 0,$$

ce qui s'écrit $ES(\alpha + \epsilon) \leq ES(\alpha)$.

5. (a) La propriété traduit l'intérêt de la diversification: la somme nécessaire pour couvrir le risque d'un portefeuille constitué de deux titres est inférieure à la somme totale requise pour couvrir les deux titres séparément.
- (b) Pour cette loi, on a $\text{VaR}_{L_1}(\alpha) = -\log \alpha$. La fonction de répartition de $L_1 + L_2$ est $F(x) = (1 - e^{-x} - xe^{-x}) \mathbb{1}_{x > 0}$. Par suite $\text{VaR}_{L_1 + L_2}(\alpha)$ est la solution de l'équation

$$e^{-x}(1 + x) = \alpha.$$

La fonction $G(x) = 1 - F(x)$ est évidemment décroissante et on vérifie facilement que $G(2\text{VaR}_{L_1}(\alpha)) < \alpha$. Par suite, la propriété (P) est vérifiée pour cette loi.

Exercice 2:

1. Un estimateur est le quantile empirique d'ordre $1 - \alpha$ de la distribution de perte.
2. Pour cette loi, la fonction de répartition est $F(x) = (1 - x^{-2}) \mathbb{1}_{x>1}$. En résolvant $F(x) = 1 - \alpha$ on trouve le quantile $\xi_{1-\alpha} = \alpha^{-1/2}$. Par suite, $f(\xi_{1-\alpha}) = 2\alpha^{3/2}$ et la loi asymptotique de l'estimateur de la VaR est la $\mathcal{N}(0, \omega_{1-\alpha}^2)$, avec

$$\omega_{1-\alpha}^2 = \frac{\alpha(1 - \alpha)}{4\alpha^3} = \frac{1 - \alpha}{4\alpha^2}.$$

Lorsque α tend vers zéro, la variance asymptotique tend vers l'infini. Ceci traduit la difficulté d'estimer la VaR avec précision pour des valeurs de α trop petites.

3. (a) Voir cours.
- (b) $X_i \hat{\beta}(1 - \alpha)$ s'interprète comme la VaR estimée de la perte L_i sachant X_i . On retrouve la VaR non conditionnelle lorsque $X_i = 1$ pour tout i .
- (c) Lorsque α décroît, la VaR devrait augmenter. Cette propriété n'est pas garantie pour les estimateurs obtenus par cette méthode.
- (d) Dans une régression classique, on teste parfois l'indépendance entre les termes d'erreurs et les régresseurs, X_i , en régressant les résidus sur une fonction non linéaire des X_i (par exemple X_i^2). Des méthodes similaires peuvent être envisagées pour la régression quantile.

ENSAE - 3ème année, Master MASEF

Février 2009

MESURES DE RISQUE

Examen

Durée: 2 heures. Sans document.

Les exercices sont indépendants.

Exercice 1: Soit L une variable de perte de fonction de répartition F_L supposée continue et strictement croissante. Soit $\alpha \in]0, 1[$ et X une variable à valeurs dans $[1 - \alpha, 1]$. On pose

$$r(L) = E\{F^{-1}(X)\} = \int_{1-\alpha}^1 F^{-1}(u) dG(u),$$

où G est la fonction de répartition de X .

1. Expliquer en quoi r définit une mesure de risque et comment elle se compare à la VaR.
2. Pour quelle loi de X obtient-on l'expected shortfall au niveau α ?
3. Ecrire $r(L)$ en fonction de Φ lorsque L s'écrit $L = m + \sigma\epsilon$ où ϵ suit la loi $\mathcal{N}(0, 1)$ de fonction de répartition Φ .
4. Montrer que r est une mesure de risque monotone, positivement homogène et invariante par translation. Quelle(s) propriété(s) supplémentaire(s) faudrait-il vérifier pour avoir une mesure de risque cohérente?
5. Soient $U_1, \dots, U_n$ des variables indépendantes de même loi uniforme sur $[1 - \alpha, 1]$. Soit $V_n = \max_{1 \leq i \leq n}(U_i)$. On définit une suite de mesures de risque en posant

$$r_n(L) = E\{F^{-1}(V_n)\}.$$

Exprimer $r_n(L)$ sous forme intégrale. Etudier l'effet d'une augmentation de n sur la pondération des risques.

6. Soient $W, W_1, \dots, W_n$ des variables indépendantes de même loi, telles $\min_{1 \leq i \leq n}(W_i)$ ait une loi uniforme sur $[1 - \alpha, 1]$. On définit une suite de mesures de risque en posant

$$r_n^*(L) = E\{F^{-1}(W)\}.$$

Exprimer $r_n^*(L)$ sous forme intégrale. Intuitivement ou par le calcul, augmenter n correspond-il à une optique plus ou moins prudente dans le calcul des réserves?

7. A partir de n observations de L proposer une estimation de $r(L)$.

Exercice 2: On suppose que pour une série de rendements en logarithmes, $r_t = \log(p_t/p_{t-1})$, on a le modèle

$$\begin{cases} r_t &= \phi r_{t-1} + \sigma_t \eta_t, & |\phi| < 1, & (\eta_t) \text{ iid } \mathcal{N}(0, 1) \\ \sigma_t^2 &= \omega + \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2, & \omega \geq 0, \lambda \in [0, 1]. \end{cases} \quad (\text{A.1})$$

On suppose que η_t est indépendante de σ_t . La VaR, conditionnelle au passé jusqu'à la date t , au niveau α , de la variable de perte $L_{t,t+h} = -(r_{t+1} + \dots + r_{t+h})$ est notée $\text{VaR}_{t,h}(\alpha)$. L'expected shortfall est noté $\text{ES}_{t,h}(\alpha)$.

1. Pour $h = 1$, justifier la formule

$$\text{VaR}_{t,1}(\alpha) = -\phi r_t + \sigma_{t+1} \Phi^{-1}(1 - \alpha)$$

et établir une formule analogue pour $\text{ES}_{t,1}(\alpha)$.

2. Dans le cas où $\phi = \omega = 0$ la formule

$$\text{VaR}_{t,h}(\alpha) = \sigma_{t+1} \sqrt{h} \Phi^{-1}(1 - \alpha),$$

est souvent utilisée. Pourquoi est-elle généralement erronée? pour quelle valeur de λ est-elle correcte?

3. On définit une variable de perte $\tilde{L}_{t,t+h} = -(p_{t+h} - p_t)$, correspondant aux variations de prix (plutôt qu'au variations des logarithmes des prix comme dans ce qui précède). On note $\tilde{\text{VaR}}_{t,h}(\alpha)$, la VaR de cette variable de perte. Etablir la formule reliant $\text{VaR}_{t,h}(\alpha)$ et $\tilde{\text{VaR}}_{t,h}(\alpha)$.
4. Supposons que l'on ait un portefeuille constitué, à proportions égales, de deux titres indépendants, dont les rendements vérifient tous les deux le modèle (A.1). Est-il correct d'utiliser comme réserves (en euros) pour couvrir le risque au niveau α le double de ce qu'on utiliserait pour l'un des deux titres?
5. On dispose d'observations $r_1, \dots, r_T$. On ne suppose plus que la loi des η_t est connue. Ayant estimé les paramètres ϕ, ω, λ comment estimer $\text{VaR}_{T,1}(\alpha)$? quelles procédures peut-on utiliser pour évaluer les performances de la VaR si l'on dispose d'observations supplémentaires $r_{T+1}, \dots, r_{T+n}$?

Eléments de corrigé

Exercice 1:

1. Puisque F est continue et strictement croissante, elle est inversible d'inverse la fonction quantile. En particulier, la VaR au niveau α est $\text{VaR}(\alpha) = F^{-1}(1 - \alpha)$. La quantité $r(L)$ s'interprète comme une mesure de distorsion, obtenue en pondérant les quantiles d'ordres supérieurs à $1 - \alpha$. La Var est obtenue en prenant pour loi de X la masse de Dirac en $1 - \alpha$. Puisque F^{-1} est strictement croissante (F étant continue), on a $\text{VaR}(\alpha) < r(L)$.
2. L'expected shortfall correspond à une loi uniforme sur $[1 - \alpha, 1]$:

$$ES(\alpha) = \frac{1}{\alpha} \int_{1-\alpha}^1 F^{-1}(u) du = \frac{1}{\alpha} \int_0^\alpha F^{-1}(1 - u) du.$$

3. On a $F^{-1}(u) = m + \sigma \Phi^{-1}(u)$, $\forall u \in [0, 1]$. Donc

$$r(L) = m \int_{1-\alpha}^1 dG(u) + \sigma \int_{1-\alpha}^1 \Phi^{-1}(u) dG(u) = m + \sigma \int_{1-\alpha}^1 \Phi^{-1}(u) dG(u)$$

puisque G est une loi de probabilité sur $[1 - \alpha, 1]$.

4. Soit $L_1 \leq L_2$. On sait que la VaR étant monotone, on a $F_{L_1}^{-1}(u) \leq F_{L_2}^{-1}(u)$ pour tout u . Donc $r(L_1) \leq r(L_2)$, ce qui montre que r est monotone. De même, r est positivement homogène et invariante par translation. Il faut de plus la sous-additivité pour avoir une mesure cohérente, c'est-à-dire $r(L_1 + L_2) \leq r(L_1) + r(L_2)$, $\forall L_1, L_2$.
5. La fonction de répartition de V_n est donnée, pour $x \in [0, 1]$, par

$$F_{V_n}(x) = P[V_n \leq x] = \{P(U_i \leq x)\}^n = \left\{ \frac{x - (1 - \alpha)}{\alpha} \right\}^n \mathbb{1}_{x \in [1 - \alpha, 1]}.$$

Par suite

$$r_n(L) = \int_{1-\alpha}^1 F^{-1}(u) \frac{n}{\alpha} \left\{ \frac{u - (1 - \alpha)}{\alpha} \right\}^{n-1} du.$$

Quand n augmente, la masse de la loi de V_n tend à se concentrer autour de 1. Par suite les gros risques seront de plus en plus pondérés.

6. Soit F_W la fonction de répartition (dépendant de n) des variables W_i . On a, pour $x \in [1 - \alpha, 1]$,

$$P[\min_{1 \leq i \leq n} W_i \geq x] = [1 - F_W(x)]^n = \frac{1 - x}{\alpha}.$$

Par suite

$$F_W(x) = 1 - \left\{ \frac{1 - x}{\alpha} \right\}^{1/n}$$

et

$$r_n^*(L) = \int_{1-\alpha}^1 F^{-1}(u) \frac{1}{n\alpha} \left\{ \frac{1 - u}{\alpha} \right\}^{1/n-1} du.$$

Lorsque n augmente, W tend à prendre des valeurs de plus en plus grandes (à se concentrer autour de 1). Donc les réserves tendent à augmenter.

7. Soit F_n est la fonction de répartition empirique des L_i : $F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{L_i \leq x}$. Soit i_0 tel que $1 - \alpha \in [(i_0 - 1)/n, i_0/n]$. Un estimateur de $r(L)$ est

$$\begin{aligned} \int_{1-\alpha}^1 F_n^{-1}(u) dG(u) &= \sum_{i=1}^n L_{i,n} \int_{1-\alpha}^1 \mathbb{1}_{[(i-1)/n, i/n]}(u) dG(u) \\ &= L_{i_0,n} \int_{1-\alpha}^{i_0/n} dG(u) + \sum_{i=i_0+1}^n L_{i,n} \int_{(i-1)/n}^{i/n} dG(u) \\ &= L_{i_0,n} \left\{ G\left(\frac{i_0}{n}\right) - G(1 - \alpha) \right\} \\ &\quad + \sum_{i=i_0+1}^n \left\{ G\left(\frac{i}{n}\right) - G\left(\frac{i-1}{n}\right) \right\} L_{i,n}. \end{aligned}$$

Exercice 2:

1. La variable $L_{t,t+1} = -r_{t+1}$ est d'espérance conditionnelle $-\phi r_t$ et de variance conditionnelle σ_{t+1}^2 . D'où la formule. De même

$$\text{ES}_{t,1}(\alpha) = -\phi r_t + \frac{\sigma_{t+1}}{\alpha} \int_0^\alpha \Phi^{-1}(1 - u) du = -\phi r_t + \frac{\sigma_{t+1}}{\alpha} \varphi\{\Phi^{-1}(1 - \alpha)\}$$

où φ est la densité de la $\mathcal{N}(0, 1)$.

2. Voir cours. La formule est correcte pour $\lambda = 1$ car dans ce cas les r_t sont iid de loi $\mathcal{N}(0, \sigma^2)$.
3. On a

$$\begin{aligned}
 P(\tilde{L}_{t,t+h} \leq x) &= P(p_{t+h} \geq p_t - x) = P\left(\frac{p_{t+h}}{p_t} \geq \frac{p_t - x}{p_t}\right) \\
 &= P\left(\log \frac{p_{t+h}}{p_t} \geq \log \frac{p_t - x}{p_t}\right) \\
 &= P\left(L_{t,t+h} \leq -\log \frac{p_t - x}{p_t}\right).
 \end{aligned}$$

Donc

$$\text{VaR}_{t,h}(\alpha) = -\log \left(1 - \frac{\tilde{\text{VaR}}_{t,h}(\alpha)}{p_t}\right).$$

4. En notant r_{1t} et r_{2t} les deux rendements, la somme vérifie

$$r_{1t} + r_{2t} = \phi(r_{1,t-1} + r_{2,t-1}) + (\sigma_{1t} + \sigma_{2t})\eta_t$$

donc la formule correcte est, à horizon 1,

$$\text{VaR}_{t,1}(\alpha) = -\phi(r_{1,t-1} + r_{2,t-1}) + (\sigma_{1t} + \sigma_{2t})\Phi^{-1}(1 - \alpha)$$

ce qui ne correspond pas au double.

5. Si les η_t ont pour fonction de répartition F , on a

$$\text{VaR}_{t,1}(\alpha) = -\phi r_t + \sigma_{t+1}F^{-1}(1 - \alpha).$$

On peut estimer F^{-1} par la fonction quantile empirique des $\hat{\eta}_t = \frac{r_t - \hat{\phi}r_{t-1}}{\hat{\sigma}_t}$.

A partir d'observations supplémentaires, on peut considérer le nombre de dépassements des VaR estimées sur l'échantillon et effectuer des tests de validation.

ENSAE - 3ème année, Master MASEF

février 2010

MESURES DE RISQUE

Examen

Durée: 2 heures. Sans document.

Les exercices sont indépendants.

Exercice 1: Supposons qu'il y ait N sources de risque. On note $L_{t+1}^{(i)}$ la perte engendrée par l'actif i entre les dates t et $t + 1$. On considère le modèle suivant:

$$L_{t+1}^{(i)} = (a + bZ_{t+1}^2)^{1/2}u_{t+1}^{(i)}, \quad i = 1, \dots, N \quad (\text{A.1})$$

où (Z_t) est un processus iid, inobservable, de densité f ; les $(u_t^{(i)})$ sont des bruits blancs indépendants entre eux et indépendants de (Z_t) , de loi $\mathcal{N}(0, \sigma_i^2)$; a et b sont des paramètres strictement positifs.

On définit la perte globale par

$$L_{t+1} = \sum_{i=1}^N L_{t+1}^{(i)} = (a + bZ_{t+1}^2)^{1/2}u_{t+1},$$

où $u_{t+1} = \sum_{i=1}^N u_{t+1}^{(i)}$. On note Φ la fonction de répartition de la loi $\mathcal{N}(0, 1)$.

1. Comment s'interprète le processus (Z_t) dans ce modèle?
2. Les variables de perte $L_{t+1}^{(i)}$ sont-elles corrélées (à t fixé lorsque i varie)? indépendantes?
3. Expliquer pourquoi VaR conditionnelle et non conditionnelle de l'actif i coïncident pour ce modèle.
4. Montrer que la VaR au niveau α et à horizon 1 de l'actif i , notée $\text{VaR}^{(i)}(\alpha)$, est solution de l'équation

$$\int_{-\infty}^{+\infty} \Phi \left(\frac{\text{VaR}^{(i)}(\alpha)}{(a + bz^2)^{1/2}\sigma_i} \right) f(z) dz = c$$

où c est une constante que l'on exprimera en fonction de α .

5. Déterminer de même l'équation caractérisant la VaR de la perte globale à horizon 1, notée $\text{VaR}(\alpha)$.
6. Résoudre ces équations dans le cas où $b = 0$. Comparer dans ce cas $\text{VaR}(\alpha)$ et $\sum_{i=1}^N \text{VaR}^{(i)}(\alpha)$. Ce résultat est-il étonnant?
7. Exprimer l'expected shortfall de l'actif i sous la forme

$$ES^{(i)}(\alpha) = K \int_{-\infty}^{+\infty} (a + bz^2)^{1/2} \phi \left(\frac{\text{VaR}^{(i)}(\alpha)}{(a + bz^2)^{1/2} \sigma_i} \right) f(z) dz$$

où ϕ est la densité de la loi $\mathcal{N}(0, 1)$ et K est une constante que l'on précisera.

Exercice 2: Soit L une variable de perte de fonction de répartition F supposée continue et strictement croissante.

1. Expliquer pourquoi on définit une mesure de risque en posant

$$r(L) = \nu \int_0^1 F^{-1}(1-u)(1-u)^{\nu-1} du, \quad \nu > 0.$$

2. Ecrire $r(L)$ en fonction de Φ lorsque L s'écrit $L = m + \sigma\epsilon$ où ϵ suit la loi $\mathcal{N}(0, 1)$ de fonction de répartition Φ .
3. Etudier l'effet du choix de ν sur la pondération des risques.
4. Vérifier que $r(L)$ est une mesure de risque monotone, positivement homogène et invariante en translation. Cela suffit-il pour en faire une mesure cohérente?
5. Vérifier que $r(L) = \nu E[L\{F(L)\}^{\nu-1}]$. En déduire que pour $\nu = 1$ la mesure de risque vérifie la propriété de sous-additivité. Cela est-il étonnant?
6. Si L et L' sont des variables comonotones, c'est-à-dire fonctions croissantes d'une même variable Z , vérifier que $r(L + L') = r(L) + r(L')$. Quelle est l'interprétation financière de cette propriété?
7. A partir de n observations $L_1, \dots, L_n$ de L proposer une estimation $r_n(L)$ de $r(L)$. On exprimera $r_n(L)$ en fonction de la suite décroissante $(L_{n,n-i})_{i=0, \dots, n-1}$ construite à partir des observations.

Eléments de corrigé

Exercice 1:

1. Z_t s'interprète comme un facteur de risque commun. Ce risque intervient dans la volatilité des variables de perte et non dans la moyenne comme dans le modèle vu en cours.

2. Les variables de perte $L_{t+1}^{(i)}$ ne sont pas corrélées mais leurs carrés le sont:

$$\begin{aligned}
 EL_{t+1}^{(i)} &= E((a + bZ_{t+1}^2)^{1/2})E(u_{t+1}^{(i)}) = 0, \\
 \text{cov}(L_{t+1}^{(i)}, L_{t+1}^{(j)}) &= EL_{t+1}^{(i)}L_{t+1}^{(j)} = E(a + bZ_{t+1}^2)E(u_{t+1}^{(i)})E(u_{t+1}^{(j)}) = 0, \\
 E(L_{t+1}^{(i)})^2 &= E(a + bZ_{t+1}^2)\sigma_i^2, \\
 E(L_{t+1}^{(i)}L_{t+1}^{(j)})^2 &= E(a + bZ_{t+1}^2)^2\sigma_i^2\sigma_j^2, \\
 \text{cov}((L_{t+1}^{(i)})^2, (L_{t+1}^{(j)})^2) &= \text{var}(a + bZ_{t+1}^2)\sigma_i^2\sigma_j^2 \neq 0.
 \end{aligned}$$

3. Les variables de perte $L_{t+1}^{(i)}$ étant indépendantes temporellement, Var conditionnelle et inconditionnelle coïncident.

4. $\text{VaR}^{(i)}(\alpha)$ est solution de l'équation

$$P((a + bZ_{t+1}^2)^{1/2}u_{t+1}^{(i)} \leq \text{VaR}^{(i)}(\alpha)) = 1 - \alpha.$$

En conditionnant par rapport à Z_{t+1} on obtient $c = 1 - \alpha$, car

$$\begin{aligned}
 1 - \alpha &= E[P((a + bZ_{t+1}^2)^{1/2}u_{t+1}^{(i)} \leq \text{VaR}^{(i)}(\alpha) \mid Z_{t+1})] \\
 &= E[\Phi\{(a + bZ_{t+1}^2)^{-1/2}\text{VaR}^{(i)}(\alpha)\}] \\
 &= \int_{-\infty}^{+\infty} \Phi\left(\frac{\text{VaR}^{(i)}(\alpha)}{(a + bz^2)^{1/2}\sigma_i}\right) f(z)dz.
 \end{aligned}$$

5. En posant $\sigma^2 = \sum_{i=1}^N \sigma_i^2$, on obtient

$$\int_{-\infty}^{+\infty} \Phi\left(\frac{\text{VaR}(\alpha)}{(a + bz^2)^{1/2}\sigma}\right) f(z)dz = 1 - \alpha \quad (\text{A.2})$$

6. Lorsque $b = 0$, on a $\text{VaR}^{(i)}(\alpha) = a\sigma_i\Phi^{-1}(1 - \alpha)$ et $\text{VaR}(\alpha) = a\sigma\Phi^{-1}(1 - \alpha)$. Donc, puisque $\sigma \leq \sum_{i=1}^N \sigma_i$, on a $\text{VaR}(\alpha) \leq \sum_{i=1}^N \text{VaR}^{(i)}(\alpha)$. Cette propriété de sous-additivité n'est en général pas vérifiée pour la VaR, mais on sait qu'elle l'est dans le cas gaussien (c'est le cas ici puisque $b = 0$).

7. On sait que $ES^{(i)}(\alpha) = \frac{1}{\alpha}E(L_{t+1}^{(i)} \mathbb{1}_{L_{t+1}^{(i)} > \text{VaR}^{(i)}(\alpha)})$. On trouve $K = \frac{\sigma_i}{\alpha}$, en utilisant le fait que $E(U \mathbb{1}_{U > c}) = \phi(c)$ où U suit la loi normale standard.

Exercice 2:

1. $r(L)$ est de la forme $\int_0^1 F^{-1}(1-u) dG(u)$, avec $G(u) = 1 - (1-u)^\nu$ une fonction de répartition sur $[0, 1]$. Il s'agit donc d'une mesure de distorsion.
2. On a $F^{-1}(1-u) = m + \sigma\Phi^{-1}(1-u)$ et par suite

$$r(L) = m + \sigma\nu \int_0^1 \Phi^{-1}(1-u)(1-u)^{\nu-1} du.$$

3. On a $G''(u) = -\nu(\nu-1)(1-u)^{\nu-2}$. Par suite G est concave pour $\nu(\nu-1) \geq 0$, c'est-à-dire pour $\nu \geq 1$. Pour de tels ν , les quantiles $F^{-1}(1-u)$ sont affectés d'un poids d'autant plus grand que u est proche de 0: les grands risques sont donc fortement pris en compte. A l'inverse, si $\nu < 1$, ces risques extrêmes ont la plus petite pondération.
4. Les propriétés de monotonie, d'homogénéité et d'invariance découlent de ces propriétés pour la VaR, en utilisant les propriétés de l'intégrale. Il manque la sous-additivité pour avoir une mesure cohérente. Celle-ci peut être vérifiée lorsque G est concave.
5. Il suffit de faire le changement de variable $u = 1 - F(p)$ dans l'intégrale. Pour $\nu = 1$ on obtient l'espérance de la variable de perte et la propriété de sous-additivité (même d'additivité) est vérifiée. Dans ce cas $r(L)$ peut être vu comme l'ES au niveau $\alpha = 1$. Or on sait que l'ES est sous-additive.
6. La vérification se fait comme pour l'ES (voir cours). Des pertes comonotones évoluent simultanément. Il n'y a donc pas de possibilité de diversification lorsqu'on agrège les portefeuilles correspondant à ces pertes.
7. Un estimateur de $r(L)$ peut être défini à partir de la fonction quantile empirique:

$$r_n(L) = \int_0^1 F_n^{\leftarrow}(1-u) dG(u),$$

soit, sous forme plus explicite,

$$r_n(L) = \sum_{i=0}^{n-1} \left\{ G\left(\frac{i+1}{n}\right) - G\left(\frac{i}{n}\right) \right\} L_{n,n-i}.$$

Appendix B

Quantile

B.1 Fonction quantile

Pour une v.a.r. X , la fonction de répartition est définie par

$$F : x \mapsto F(x) = P[X \leq x].$$

Elle est croissante, continue à droite, avec une limite à gauche en tout point. Si X admet une densité, F est continue. Si cette densité est positive sur $\mathbb{R}$, F est strictement croissante.

On définit *l'inverse généralisée* d'une fonction T croissante sur $\mathbb{R}$ par

$$T^{\leftarrow}(y) = \inf\{x \in \mathbb{R} \mid T(x) \geq y\},$$

avec la convention que l'inf d'un ensemble vide est $+\infty$. Ainsi $T^{\leftarrow}$ est continue à gauche.

Définition B.1 *L'inverse généralisée d'une fonction de répartition F*

$$F^{\leftarrow}(\alpha) = \inf\{x \in \mathbb{R} \mid F(x) \geq \alpha\}, \quad 0 < \alpha < 1$$

est appelée fonction quantile. La quantité $x_{(\alpha)} = F^{\leftarrow}(\alpha)$ définit le α -quantile de F .

Si F est continue et strictement croissante, on a simplement $F^{\leftarrow}(\alpha) = F^{-1}(\alpha)$. On a la caractérisation suivantes:

$$x_0 = F^{\leftarrow}(\alpha) \Leftrightarrow F(x_0) \geq \alpha \text{ et } F(x) < \alpha, \forall x < x_0.$$

Pour une loi à densité positive sur $\mathbb{R}$, le quantile d'ordre α est caractérisé par $P[X < F^{\leftarrow}(\alpha)] = \alpha$. On définit de même la fonction (décroissante) quantile à droite q_d par $P[X > q_d(\alpha)] = \alpha$. C'est l'inverse de la fonction de survie.

Exemple B.1 Si $X \sim \mathcal{N}(\mu, \sigma^2)$ alors $x_{(\alpha)} = m + \sigma\Phi^{-1}(1 - \alpha)$ où Φ est la f.r. de la loi $\mathcal{N}(0, 1)$. Si X est une perte m s'interprète comme la *perte anticipée* et $\sigma\Phi^{-1}(1 - \alpha)$ comme la *perte non anticipée*.

On a les propriétés suivantes, immédiates à démontrer: pour tout $0 < \alpha < 1$

- si $X = c$ p.s. où c est une constante, $F_X^{\leftarrow}(\alpha) = c$,
- si $Y = X + c$ où c est une constante, $F_Y^{\leftarrow}(\alpha) = F_X^{\leftarrow}(\alpha) + c$,
- si $Y = \lambda X$ où $\lambda \geq 0$ est une constante, $F_Y^{\leftarrow}(\alpha) = \lambda F_X^{\leftarrow}(\alpha)$.

En utilisant la propriété: $F(x) \geq \alpha \Leftrightarrow x \geq F^{\leftarrow}(\alpha)$, on montre le résultat suivant.

Proposition B.1 Soit U une v.a. de loi uniforme sur $[0, 1]$ et X une v.a. de loi F . Alors

- (i) $P[F^{\leftarrow}(U) \leq x] = F(x)$, i.e. $F^{\leftarrow}(U)$ a même loi que X .
- (ii) Si F est continue, alors $F(X)$ a même loi que U .

B.2 Agrégation de fonctions quantiles

Les fonctions quantiles (et plus généralement les mesures de risque) s'agrègent mal. On dispose rarement de formules explicites (d'où le recours aux simulations). Ceci pose la question de la réallocation des réserves entre les services.

Plaçons nous dans le cas gaussien. Si

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix} \right),$$

on a

$$\begin{aligned} F_X^{\leftarrow}(\alpha) &= m_X + \sigma_X\Phi^{-1}(1 - \alpha), \\ F_Y^{\leftarrow}(\alpha) &= m_Y + \sigma_Y\Phi^{-1}(1 - \alpha), \\ F_{X+Y}^{\leftarrow}(\alpha) &= m_X + m_Y + (\sigma_X^2 + \sigma_Y^2 + 2\rho\sigma_X\sigma_Y)^{1/2}\Phi^{-1}(1 - \alpha). \end{aligned}$$

Il n'y a donc pas de relation analytique entre le quantile de la somme et ceux de X et Y (sauf si $\rho = 1$ mais alors X et Y sont proportionnelles). On a toujours

$$F_{X+Y}^{\leftarrow}(\alpha) \leq F_X^{\leftarrow}(\alpha) + F_Y^{\leftarrow}(\alpha).$$

Pour des variables gaussiennes, la VaR vérifie donc la propriété de sous-additivité (voir la définition 2.3). Il est facile de construire un exemple de variables discrètes où cette propriété est en défaut.

Exemple B.2 Soit X, Y deux v.a. indépendantes de même loi:

$$P[X = 0] = 1 - p, \quad P[X = 1] = p, \quad 0 < p < 1.$$

Pour $(1 - p)^2 < \alpha \leq 1 - p$ on a $F_X^{\leftarrow}(\alpha) = F_Y^{\leftarrow}(\alpha) = 0$ et $F_{X+Y}^{\leftarrow}(\alpha) \geq 1$.

B.3 Dérivées du quantile d'une combinaison linéaire

Lemme B.1 (Gouriéroux, Laurent, Scaillet, 2000) Soit $(X, Y) \in \mathbb{R}^2$ un vecteur aléatoire de loi absolument continue de densité f et tel que $E|Y| < \infty$. Soit $Q(\epsilon, \alpha)$ le quantile défini par

$$P[X + \epsilon Y > Q(\epsilon, \alpha)] = \alpha.$$

Alors

$$\frac{\partial Q(\epsilon, \alpha)}{\partial \epsilon} = E[Y \mid X + \epsilon Y = Q(\epsilon, \alpha)].$$

Preuve: On a

$$\alpha = \int \left(\int_{Q(\epsilon, \alpha) - \epsilon y}^{+\infty} f(x, y) dx \right) dy.$$

En dérivant cette égalité par rapport à ϵ on obtient

$$0 = \int f(Q(\epsilon, \alpha) - \epsilon y, y) \left(\frac{\partial Q(\epsilon, \alpha)}{\partial \epsilon} - y \right) dy.$$

D'où

$$\frac{\partial Q(\epsilon, \alpha)}{\partial \epsilon} = \frac{\int y f(Q(\epsilon, \alpha) - \epsilon y, y) dy}{\int f(Q(\epsilon, \alpha) - \epsilon y, y) dy} = E[Y \mid X + \epsilon Y = Q(\epsilon, \alpha)].$$

B.4 VaR et expected shortfall pour variables non absolument continues

Dans le cas de variables de perte dont la loi n'est pas absolument continue par rapport à la mesure de Lebesgue, ou pour des variables continues dont la densité n'est pas partout strictement positive, il peut être nécessaire de distinguer plusieurs quantiles.

On appelle, α -quantile inférieur de X

$$q_\alpha = F^{\leftarrow}(\alpha) = \inf\{x \in \mathbb{R} \mid F(x) \geq \alpha\}$$

et α -quantile supérieur de X

$$q^\alpha = \inf\{x \in \mathbb{R} \mid F(x) > \alpha\}.$$

On a bien sûr $q_\alpha \leq q^\alpha$, avec égalité si et seulement si $F(x) = \alpha$ pour au plus un x .

On définit de même deux notions de VaR pour une perte X :

$$\text{VaR}_\alpha = q_{1-\alpha}, \quad \text{VaR}^\alpha = q^{1-\alpha}.$$

On définit les "tail conditional expectations" (TCE) d'une variable X telle que $E(X^+) < \infty$ par

$$\text{TCE}_\alpha = E[X \mid X \geq \text{VaR}_\alpha], \quad \text{TCE}^\alpha = E[X \mid X \geq \text{VaR}^\alpha].$$

On a bien sûr $\text{TCE}_\alpha \leq \text{TCE}^\alpha$. Il est possible de construire des exemples simples montrant que TCE_α n'est pas une mesure de risque sous-additive (voir Acerbi et Tasche, 2002). Sous certaines conditions de régularité, on montre que la plus petite mesure de risque qui soit cohérente et plus grande que la VaR est la "worst conditional expectation" (WCE) définie par

$$\text{WCE}_\alpha = \inf\{E[X \mid A]; P(A) > \alpha\}$$

(voir Delbaen, 2002).

Finalement, on définit l'expected shortfall, pour X telle que $E(X^+) \leq +\infty$, par

$$\text{ES}_\alpha = \frac{1}{\alpha} \{E(X \mathbf{1}_{X \geq s}) + s(\alpha - P[X \geq s])\}, \quad s \in [q_{1-\alpha}, q^{1-\alpha}] \quad (\text{B.1})$$

en notant que la définition est indépendante du choix de s . On a la propriété suivante.

Proposition B.2 *Soit X telle que $E(X^+) < +\infty$. Alors*

$$\text{ES}_\alpha = \frac{1}{\alpha} \int_0^\alpha \text{VaR}_u du. \quad (\text{B.2})$$

Preuve: d'après (B.1), si $U \sim \mathcal{U}_{[0,1]}$, en posant $Z =$

$$\begin{aligned}
\alpha \text{ES}_\alpha &= E(X \mathbf{1}_{X \geq \text{VaR}_\alpha}) + \text{VaR}_\alpha(\alpha - P[X \geq \text{VaR}_\alpha]) \\
&= E(X \mathbf{1}_{X \geq \text{VaR}_\alpha}) + \text{VaR}_\alpha E(\mathbf{1}_{U \leq \alpha} - \mathbf{1}_{X \geq \text{VaR}_\alpha}) \\
&= E(X \mathbf{1}_{X \geq \text{VaR}_\alpha}) - \text{VaR}_\alpha E(\mathbf{1}_{q_{1-U} \geq q_{1-\alpha}} - \mathbf{1}_{1-U \geq 1-\alpha}) \\
&= E(X \mathbf{1}_{X \geq \text{VaR}_\alpha}) - q_{1-\alpha} E(\mathbf{1}_{(1-U < 1-\alpha) \cap (q_{1-U} \geq q_{1-\alpha})}) \\
&= E(q_{1-U} \mathbf{1}_{q_{1-U} \geq q_{1-\alpha}}) - E(q_{1-U} \mathbf{1}_{(1-U < 1-\alpha) \cap (q_{1-U} \geq q_{1-\alpha})}) \\
&= E(q_{1-U} \mathbf{1}_{U \leq \alpha})
\end{aligned}$$

car $F^{\leftarrow}(1 - U) = q_{1-U}$ a même loi que X (voir la proposition B.1).

□

B.5 Théorème central limite pour tableaux triangulaires

Soit $X_{n1}, \dots, X_{nr_n}$ une suite de variables centrées, appelée tableau triangulaire (car en général $r_n \leq n$). On pose, pour tout n et $k = 1, \dots, r_n$,

$$E(X_{nk}) = 0, \quad E(X_{nk}^2) = \sigma_{nk}^2, \quad s_n^2 = \sum_{k=1}^{r_n} \sigma_{nk}^2 \quad (\text{B.3})$$

et on suppose que $s_n > 0$ pour tout n . On a la condition dite de Lindeberg

$$\forall \epsilon > 0, \quad \lim_{n \rightarrow \infty} \sum_{k=1}^{r_n} \frac{1}{s_n^2} E(X_{nk}^2 \mathbf{1}_{|X_{nk}| > \epsilon s_n}) = 0. \quad (\text{B.4})$$

Le théorème suivant est démontré dans Billingsley (1995)¹ et généralise le TCL classique pour variables iid.

Théorème B.1 *Supposons que pour tout n la suite $X_{n1}, \dots, X_{nr_n}$ soit indépendante et vérifie (B.3) et (B.4). Alors*

$$(X_{n1} + \dots + X_{nr_n})/s_n \xrightarrow{d} \mathcal{N}(0, 1).$$

¹ *Probability and measure, 3rd edition*, John Wiley.

Appendix C

Références

Ouvrages généraux:

- GOURIÉROUX, C. ET J. JASIAK (2001) *Financial Econometrics*, Princeton University Press.
- GOURIÉROUX, C. ET A. TIOMO (2007) *Risque de crédit*, Economica.
- KOENKER, R. (2005) *Quantile regression*, Cambridge University Press.
- MCNEIL, A.J., FREY, R. ET P. EMBRECHTS (2005) *Quantitative risk Management*, Princeton University Press.

Références du chapitre 2:

- ACERBI, C. ET D. TASCHE (2002) On the coherence of expected shortfall. *Journal of Banking and Finance* 26, 1487-1503.
- ARTZNER, P., DELBAEN, F., EBER, J-M. ET D. HEATH (1999) Coherent measures of risk. *Mathematical Finance* 9, 203-228.
- DELBAEN, F. (2002) Coherent measures of risk on general probability spaces. *In : Advances in Finance and Stochastics, essays in Honor of D. Sondermann, Springer*, 1-37.
- GOURIÉROUX, C., LAURENT, J-P ET O. SCAILLET (2000) Sensitivity Analysis of VaR, *Journal of Empirical Finance*, 7, 225-246.
- GOURIÉROUX, C. ET W. LIU (2006) Sensitivity analysis of distortion risk measures, unpublished document.

- KUSUOKA, S. (2001) On law invariant coherent risk measures. In : *Advances in Mathematical Economics*, 83-95 vol. 3, Springer, Tokyo.
- MONFORT, A. (2008) Une modélisation séquentielle de la VaR. *Document non publié*.
- TASCHE, D. (2002) Expected shortfall and beyond. *Journal of Banking and Finance* 26, 1519-1533.
- WANG S. ET J. DHAENE (1998) Comonotonicity, correlation order and premium principles. *Insurance: Mathematics and Economics* 22, 235-242.
- WANG S., YOUNG V. AND H. PANJER (1997) Axiomatic Characterization of Insurance Prices. *Insurance: Mathematics and Economics* 21, 173-183.

Références du chapitre 3:

- BAHADUR, R.R. (1966) A note on quantiles in large samples. *Annals of Mathematical Statistics* 37, 577-580.
- DE ROSSI G. AND A. HARVEY (2006) Time-varying quantiles. Discussion paper CWPE 0649.
- ENGLE, R.F. ET S. MANGANELLI (2004) CAViaR: Conditional Autoregressive Value at Risk by regression quantiles. *Journal of Business and Economic Statistics*, 22, 367-381.
- GOURIÉROUX, C. AND J. JASIAK (2007) Dynamic quantile models. A paraître dans *Journal of Econometrics*.
- GOURIÉROUX, C. AND W. LIU (2007) Converting Tail-VaR to VaR: an econometric study. Unpublished document.
- KOENKER R. AND Z. XIAO (2002) Inference on the quantile regression process. *Econometrica*, 70, 1583-1612.
- KOENKER R. AND Z. XIAO (2006) Quantile autoregression. *Journal of the American Statistical Society*, 101, 980-990.
- KOENKER R. AND Q. ZHAO (1996) Conditional quantile estimation for and inference for ARCH models. *Econometric Theory*, 12, 793-813.
- KUESTER, K., MITTNIK, S. ET M.S. PAOLELLA (2006) Value at Risk prediction: a comparison of alternative strategies. *Journal of Financial Econometrics*, 4, 53-89.

- MARTIN, R. AND T. WILDE (2002) Unsystematic Credit Risk, *Risk Magazine*, 15, 123-128.
- SCAILLET, O. Nonparametric estimation of conditional expected shortfall. *Insurance and risk management journal*, 74, 639-660.
- WILDE, T. (2001) Probing Granularity. *Risk*, 14, 103-106.
- WU, W.B. (2005) On the Bahadur representation of sample quantiles for dependent sequences. *The Annals of Statistics*, 33, 1934-1963.